

最优化理论与方法

第六讲

无约束优化的下降算法

$$\min f(x), x \in R^n$$

算法 : 两个基本策略

- 线搜索法（下降算法）

$$\min_{\alpha > 0} f(x_k + \alpha p_k)$$

- 信赖域法

$$\min_p m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p$$

$$\text{s.t. } \|p\| \leq \Delta_k$$

$$\min f(x), x \in R^n \quad (2.1)$$

第二章 无约束问题的下降算法 与线性搜索

第一节 无约束问题的最优性条件

第二节 下降算法的一般步骤

第三节 线性搜索

我们先来回忆一下一元函数的极值条件(关于极小值点)

$$x \in R$$

$$x \in R^n (n > 1)$$

一阶必要条件: $f'(x^*) = 0 \Rightarrow$

$$\nabla f(x^*) = 0$$

二阶必要条件: $\begin{cases} f'(x^*) = 0 \\ f''(x^*) \geq 0 \end{cases} \Rightarrow$

$$\begin{cases} \nabla f(x^*) = 0 \\ \nabla^2 f(x^*) \text{ 半正定} \end{cases}$$

二阶充分条件: $\begin{cases} f'(x^*) = 0 \\ f''(x^*) > 0 \end{cases} \Rightarrow$

$$\begin{cases} \nabla f(x^*) = 0 \\ \nabla^2 f(x^*) \text{ 正定} \end{cases}$$

下降方向

考察无约束问题

$$\min f(x), x \in R^n \quad (2.1)$$

这里函数 $f: R^n \rightarrow R$ 是连续可微的

定义2.1.1 设 $x, d \in R^n$, 若存在数 $\bar{\alpha} > 0$, 使得

$$f(x + \alpha d) < f(x), \forall \alpha \in (0, \bar{\alpha})$$

则称 d 是函数 f 在 x 处的一个下降方向; 若 $-d$ 是下降, 则称 d 上升


定理2.1.1 设函数 f 连续可微且 $\nabla f(x) \neq 0$, 则

- (1) 若向量 d 满足 $\nabla f(x)^T d < 0$, 则 d 是 f 在 x 处的一个下降方向
- (2) 若 n 阶矩阵 H 对称正定, 则向量 $d = -H\nabla f(x)$ 是 f 在 x 处的一个下降方向. 特别, $d = -\nabla f(x)$ 是 f 在 x 处的一个下降方向.

练习: 习题2的第5题

下降方向

d 是函数 f 在点 x 处的一个下降方向



$$\nabla f(x)'d < 0,$$

下降算法的一般步骤

算法 2.1 (求解无约束问题的下降算法)

步 1 给定初始点 $x^{(0)} \in R^n$, 精度 $\epsilon > 0$. 令 $k := 0$.

步 2 若 $\|\nabla f(x^{(k)})\| \leq \epsilon$, 则终止算法, 得解 $x^{(k)}$. 否则, 转步 3.

步 3 确定下降方向 $d^{(k)}$, 使得

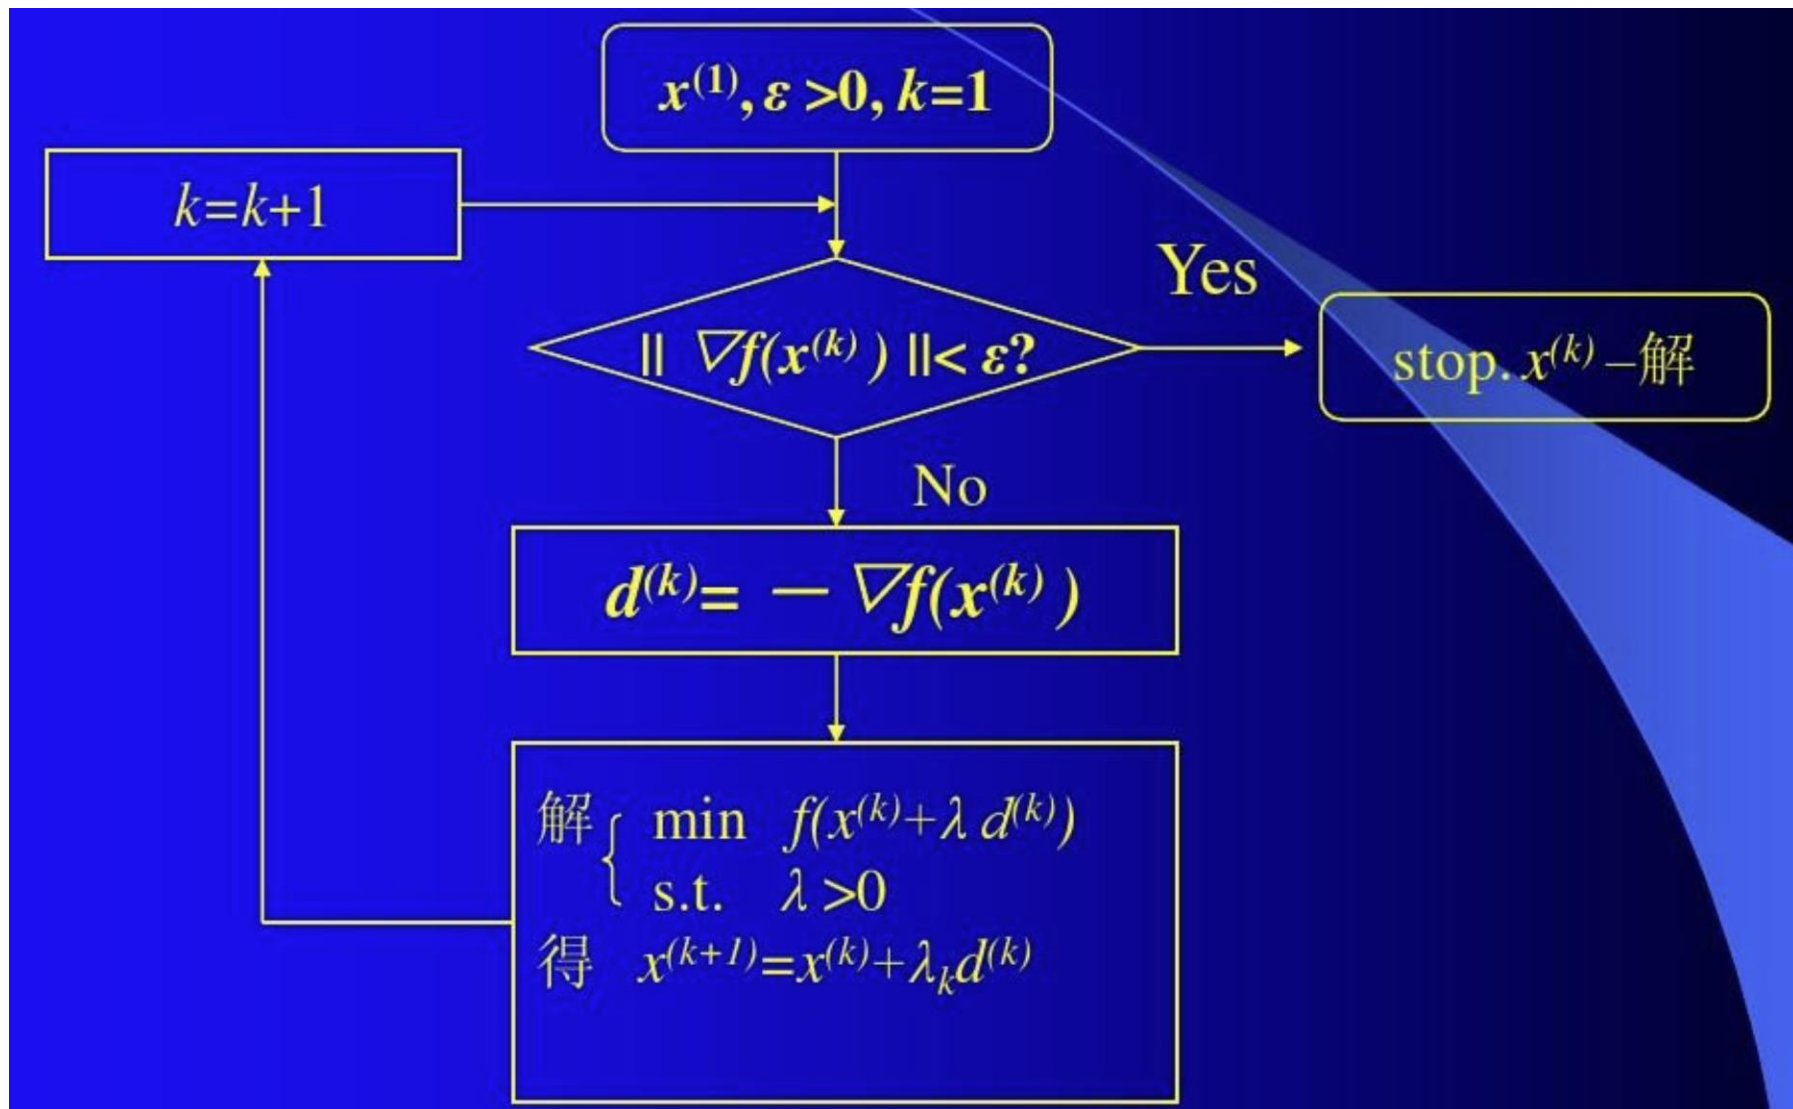
$$\nabla f(x^{(k)})^T d^{(k)} < 0.$$

步 4 确定步长 $\alpha_k > 0$ 使得

$$f(x^{(k)} + \alpha_k d^{(k)}) < f(x^{(k)}).$$

步 5 令 $x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}$, $k := k + 1$. 转步 2.

最速下降算法流程图



由下降算法的结构知,为构造一个使用的下降算法,我们的工作

主要有两部分:

已知近似最优解 x_k ,

1. 计算下降方向 d_k 满足: $\nabla f(x_k)^T d_k < 0$

基本的构造方法有两个:

(1) $d_k = -H_k \nabla f(x_k)$, 其中 H_k 是某一对称正定矩阵

(2) $d_k = -a_k \nabla f(x_k) + b_k d_{k-1}$, 即 $-\nabla f(x_k)$ 和 d_{k-1} 的线性组合

d_k 的不同构造方式对应不同的最优化算法,具体将在以后各章介绍

2. 计算步长 $\alpha_k > 0$ 满足: $f(x_k + \alpha_k d_k) < f(x_k)$

这一步主要通过线性搜索来完成——一元函数

$$\phi(\alpha) = f(x_k + \alpha d_k)$$

求极值,具体在下一节介绍


$$x^{k+1} = x^k + \alpha^k d^k, \quad k = 0, 1, \dots$$

- 最速下降法:


$$x^{k+1} = x^k - \alpha^k \nabla f(x^k), \quad k = 0, 1, \dots$$

- Newton法:

$$x^{k+1} = x^k - \alpha^k \left(\nabla^2 f(x^k) \right)^{-1} \nabla f(x^k),$$



最速下降法具有慢的收敛速度



Newton法具有很快的收敛速度（二阶）

步长 α^k 的选取：线性搜索

计算步长 α_k 的两种线性搜索：精确搜索和非精确搜索：

精确搜索： α_k 是一维优化问题的解

$$\min_{\alpha > 0} f(x_k + \alpha d_k)$$

即 α_k 满足

$$\nabla f(x_k + \alpha_k d_k)^T d_k = 0$$

非精确搜索： α_k 按照某种规则计算使之满足

$$f(x_k + \alpha_k d_k) < f(x_k)$$

即函数值有一定程度下降.

步长 α^k 的选取

精确线性搜索： α_k 是一维优化问题的解

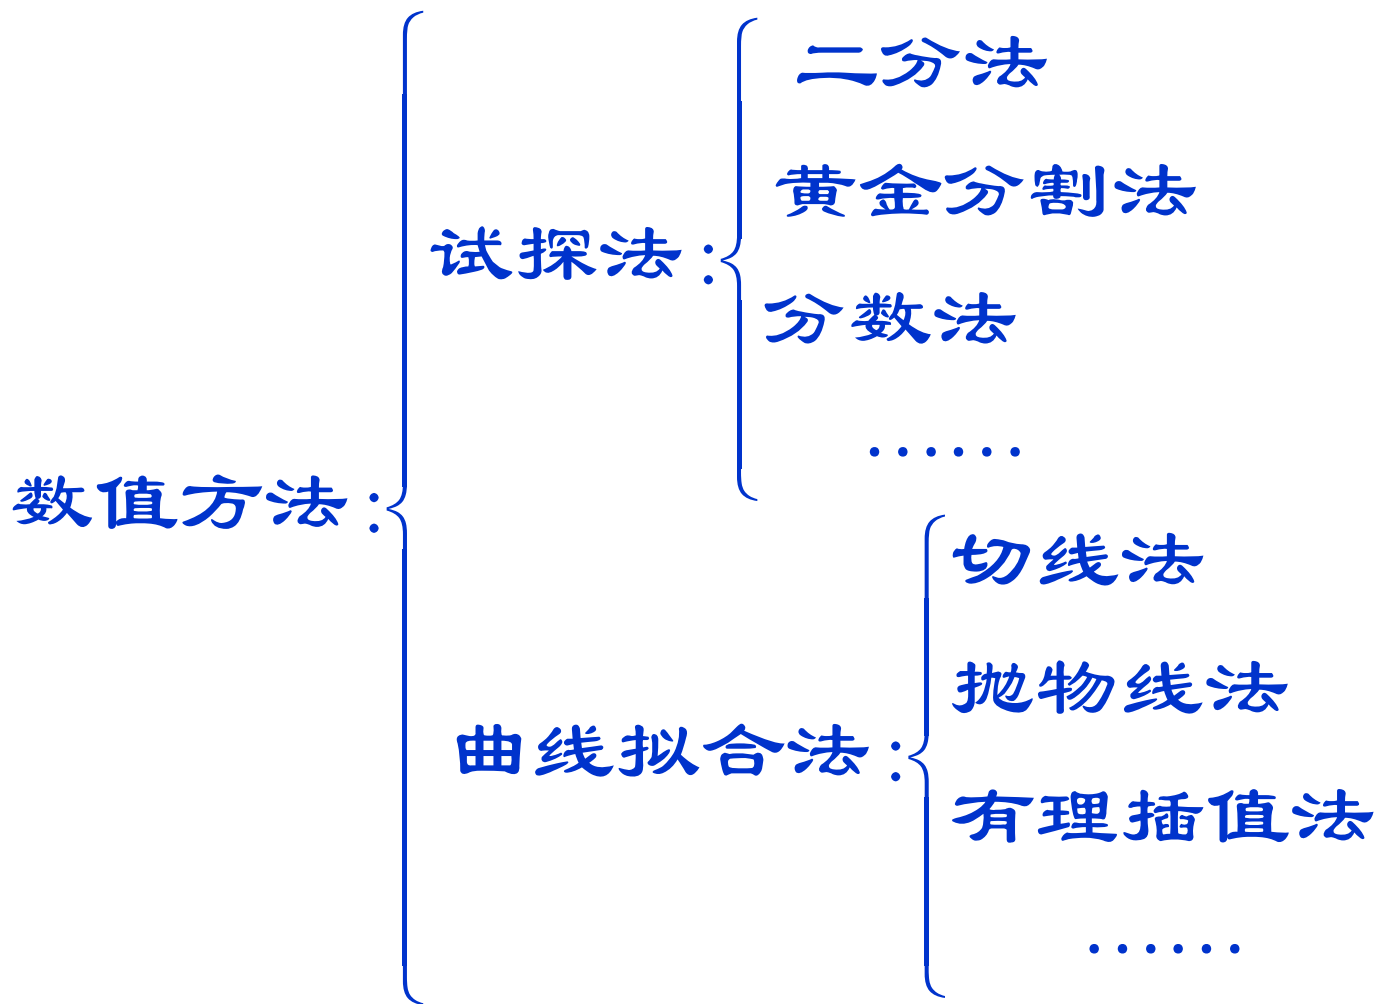
$$\min_{\alpha > 0} f(x_k + \alpha d_k)$$

令 $\phi(\alpha) = f(x_k + \alpha d_k)$, 则 $\phi'(\alpha) = \nabla f(x_k + \alpha d_k)^T d_k$

由 $\phi'(\alpha) = 0$ 得解 α_k . 所以计算 α_k 等价于解方程

$$\nabla f(x_k + \alpha d_k)^T d_k = 0 \quad (100)$$

如果方程(100)简单, 直接解方程求得 α_k ; 否则需用数值方法求近似解



直接解方程计算步长 α_k 的例子：

如二次函数

$$f(x) = \frac{1}{2} x^T Q x + q^T x + c, \quad x \in R^n$$

其中矩阵 Q 对称且正定

由于

$$\phi(\alpha) = f(x_k + \alpha d_k) = \frac{\alpha^2}{2} d_k^T Q d_k + \alpha \nabla f(x_k)^T d_k + f(x_k)$$

则
$$\phi'(\alpha) = \alpha d_k^T Q d_k + \nabla f(x_k)^T d_k$$

令 $\phi'(\alpha) = 0$ ，得解

$$\alpha_k = -\frac{\nabla f(x_k)^T d_k}{d_k^T Q d_k}$$

一、精确线性搜索——黄金分割法(0.618法)


1. 单峰函数

定义：设 $f(x)$ 是区间 $[a, b]$ 上的一元函数， \bar{x} 是 $f(x)$ 在 $[a, b]$ 上的极小点，且对任意的 $x_1, x_2 \in [a, b], x_1 < x_2$ ，有

(a) 当 $x_2 \leq \bar{x}$ 时， $f(x_1) > f(x_2)$;

(b) 当 $x_1 \geq \bar{x}$ 时， $f(x_1) < f(x_2)$.

则称 $f(x)$ 是单峰函数。




思考：根据 $f(x_1)$ 和 $f(x_2)$ 的大小关系，能否判定最小值点 \bar{x} 落在哪个区间？

性质：通过计算区间 $[a,b]$ 内两个不同点的函数值，就可以确定一个包含极小点的子区间。

定理 设 $f(x)$ 是区间 $[a,b]$ 上的单峰函数， \bar{x} 是 $f(x)$ 在 $[a,b]$ 上的极小点。任取点 $c < d \in [a,b]$ ，则有

(1) 如果 $f(c) > f(d)$ ，则 $\bar{x} \in [c,b]$;


(2) 如果 $f(c) \leq f(d)$ ，则 $\bar{x} \in [a,d]$ 。



2. 黄金分割法

思想：通过选取试探点使包含极小点的区间按相同比例不断缩短，直到区间长度小到一定程度，此时区间上各点的函数值均接近极小值。

下面推导黄金分割法的计算公式 设 $f(x)$ 在 $[a_1, b_1]$ 上单峰，极小点 $\bar{x} \in [a_1, b_1]$.



第 k 次迭代前 $\bar{x} \in [a_k, b_k]$, 取 $\lambda_k, \mu_k \in [a_k, b_k]$, 规定 $\lambda_k < \mu_k$.

计算 $f(\lambda_k)$ 和 $f(\mu_k)$, 分两种情况:


1. 若 $f(\lambda_k) > f(\mu_k)$, 则令 $a_{k+1} = \lambda_k$, $b_{k+1} = b_k$;

2. 若 $f(\lambda_k) \leq f(\mu_k)$, 则令 $a_{k+1} = a_k$, $b_{k+1} = \mu_k$.

如何确定 λ_k 与 μ_k ?

要求其满足以下两个条件：

1. λ_k 和 μ_k 到 $[a_k, b_k]$ 端点等距，即
- $$b_k - \lambda_k = \mu_k - a_k \quad (1)$$



2. 每次迭代区间长度缩短 比率相同，即

$$b_{k+1} - a_{k+1} = \alpha(b_k - a_k) \quad (\alpha > 0 \text{ 为某一缩小比例}) \quad (2)$$

$$\alpha = \frac{\sqrt{5}-1}{2} \approx 0.618 \quad \text{黄金分割比例} \quad (3)$$

(4)

黄金分割算法步骤：

1. 给定初始区间 $[a_1, b_1]$, 精度要求 $\varepsilon > 0$.
令 $\lambda_1 = a_1 + 0.382(b_1 - a_1)$, $\mu_1 = a_1 + 0.618(b_1 - a_1)$,
并计算 $f(\lambda_1)$ 与 $f(\mu_1)$. 令 $k := 1$.
2. 若 $b_k - a_k < \varepsilon$, 停止, 且 $\bar{x} = \frac{b_k + a_k}{2}$. 否则,
当 $f(\lambda_k) > f(\mu_k)$ 时, 转 3; 当 $f(\lambda_k) \leq f(\mu_k)$ 时, 转 4.
3. 令 $a_{k+1} = \lambda_k$, $b_{k+1} = b_k$, $\lambda_{k+1} = \mu_k$,
 $\mu_{k+1} = a_{k+1} + 0.618(b_{k+1} - a_{k+1})$, 计算 $f(\mu_{k+1})$, 令 $k := k + 1$, 转 2。
4. 令 $a_{k+1} = a_k$, $b_{k+1} = \mu_k$, $\mu_{k+1} = \lambda_k$,
 $\lambda_{k+1} = a_{k+1} + 0.382(b_{k+1} - a_{k+1})$, 计算 $f(\lambda_{k+1})$, 令 $k := k + 1$, 转 2。

黄金分割法的迭代效果：第 k 次迭代后所得区间长度为初始区间长度的 $(\frac{\sqrt{5}-1}{2})^k$ 倍。

黄金分割法的特点：实现比较简单,且不必预先知道探索点的个数

Fibonacci法

- 类似黄金分割法,都是分割方法,主要区别之一在于:搜索区间长度的缩短率不是采用黄金分割数,而是**Fibonacci**数。

二、 非精确线性搜索— Armijo 型线性搜索 和 Wolfe-Powell 型线性搜索

精确搜索计算量较大，非精确搜索计算量小，易于实现，其计算步长 α_k 使得 $f(x_k + \alpha_k d_k)$ 较 $f(x_k)$ 有一定下降量.


非精确搜索中最简单的是Armijo搜索

Armijo型线性搜索：给定 $\sigma_1 \in (0,1)$, 计算 α_k 满足

$$f(x_k + \alpha_k d_k) \leq f(x_k) + \sigma_1 \alpha_k \nabla f(x_k)^T d_k \quad (2.6)$$

令 $\phi(\alpha) = f(x_k + \alpha d_k)$, (2.6)等价于

$$\phi(\alpha_k) \leq \phi(0) + \sigma_1 \alpha_k \phi'(0)$$



用进退法实现Armijo搜索：逐渐变小以满足Armijo搜索条件

算法2.3 (Armijo 型线性搜索)

步0 若 $\alpha_k = 1$ 满足(2.6), 则取 $\alpha_k = 1$. 否则转下一步;

步1 给定常数 $\beta > 0, \rho \in (0, 1)$. 令 $\alpha_k = \beta$;

步2 若 α_k 满足(2.6), 则得到步长 α_k , 终止计算. 否则转步3;

步3 令 $\alpha_k := \rho \alpha_k$, 转步2.

注意：单位步长 $\alpha_k = 1$ 很重要, 它能使算法获得较快的收敛速度.

例2.3.2 给定无约束问题

$$\min f(x) = \frac{1}{2}x_1^2 + x_2^2$$

设 $x^{(0)} = (1, 1)^T$, $d^{(0)} = (1, -1)^T$. 用 Armijo 搜索计算 $\alpha_0 = 0.5^i$, 使得

$$f(x^{(0)} + \alpha_0 d^{(0)}) \leq f(x^{(0)}) + 0.9\alpha_0 \nabla f(x^{(0)})^T d^{(0)}$$

解: $\nabla f(x) = (x_1, 2x_2)^T$, $\nabla f(x^{(0)}) = (1, 2)^T$, $\nabla f(x^{(0)})^T d^{(0)} = -1 < 0$,

故 $d^{(0)}$ 是 f 在 $x^{(0)}$ 处的一个下降方向.

由于 $x^{(0)} + \alpha d^{(0)} = (1 + \alpha, 1 - \alpha)^T$,

$$\text{故 } f(x^{(0)} + \alpha d^{(0)}) - f(x^{(0)}) = \frac{1}{2}(1 + \alpha)^2 + (1 - \alpha)^2 - \frac{3}{2} = \frac{3}{2}\alpha^2 - \alpha$$

Armijo 搜索条件可以写成:

$$\frac{3}{2}\alpha^2 - \alpha \leq 0.9\alpha \times (-1) = -0.9\alpha$$

即 $\alpha \leq \frac{1}{15} \approx 0.066666$. 由 $\alpha_0 = 0.5^i \leq \frac{1}{15}$, 即得 $\alpha_0 = 0.5^4 = 0.0625$

注: (i) Armijo 型线性搜索 (2.6) 中的参数 σ_1 可取为 $(0, 1)$ 中的任何实数. 但当 $\sigma_1 \in (0, 1/2)$ 时, 可保证 Newton 法和拟 Newton 法的超线性收敛性.

(ii) 步长 $\alpha_k = 1$ 是很重要的步长. 它在算法的收敛速度分析中起到十分重要的作用.


Armijo型线性搜索的缺点: 步长可能过小

在上面的 Armijo 型线性搜索中, 试探步按比例 ρ 缩小. 若 $\rho \in (0, 1)$ 较大 (如 ρ 接近于 1), 则相邻两次试探步的改变相对较小. 此时, 需要经过较多次搜索才能得到 α_k . 若 $\rho \in (0, 1)$ 较小 (如 ρ 接近于 0), 则相邻两次试探步的改变相对较大. 此时, 可经过相对较少的试探步得到 α_k . 但获得的步长 α_k 可能很小. 为了克服 Armijo 型线性搜索的这一缺陷, 可采用下面的 Wolfe-Powell 型非精确线性搜索.

在上面关于Armijo 搜索中，参数 ρ 的选择非常重要，如果过大，则函数计算量很大；过小则产生过小的步长，为克服Armijo 搜索的这一缺陷，人们在Armijo 搜索的下降条件基础上增加防止步长过小的条件：

$$\phi'(\alpha_k) = \nabla f(x_k + \alpha_k d_k)^T d_k \geq \sigma_2 \nabla f(x_k)^T d_k$$

即曲线切线斜率具有下界 $\sigma_2 \nabla f(x_k)^T d_k$



从而得到了另一个重要的非精确搜索－Wolfe - Powell搜索。

Wolfe - Powell 线性搜索：给定常数 $0 < \sigma_1 < \sigma_2 < 1$

$$\begin{cases} f(x_k + \alpha_k d_k) \leq f(x_k) + \sigma_1 \alpha_k \nabla f(x_k)^T d_k \\ \nabla f(x_k + \alpha_k d_k)^T d_k \geq \sigma_2 \nabla f(x_k)^T d_k \end{cases} \quad (2.7)$$

为保证 α_k 的存在性，通常取 $0 < \sigma_1 < \frac{1}{2}$

令 $\phi(\alpha) = f(x_k + \alpha d_k)$ ，上面的搜索条件等价于

$$\begin{cases} \phi(\alpha_k) \leq \phi(0) + \sigma_1 \alpha_k \phi'(0) \\ \phi'(\alpha_k) \geq \sigma_2 \phi'(0) \end{cases}$$

关于 Wolfe - Powell 搜索中 α_k 的存在性，


我们有下面结论

定理 设 $f : R^n \rightarrow R$ 是连续可微的，且下有界，如果 $\nabla f(x_k)^T d_k < 0$ ，则存在一个区间 $[a, b]$ ，使得 $\forall \alpha \in [a, b]$ 满足 (2.7) 成立。

证明：因为曲线 $\phi(\alpha) = f(x_k + \alpha d_k)$ 有下界，而直线

$$l(\alpha) = f(x_k) + \alpha \sigma_1 \nabla f(x_k)^T d_k$$

单调下降，两者必定至少相交一次，



令 $\alpha' > 0$ 是其中最小的交点, 则有

$$f(x_k + \alpha' d_k) = f(x_k) + \alpha' \sigma_1 \nabla f(x_k)^T d_k \quad (1)$$

而对任意的 $\alpha \in (0, \alpha')$, 有

$$f(x_k + \alpha d_k) \leq f(x_k) + \alpha \sigma_1 \nabla f(x_k)^T d_k$$


由中值定理, 存在 $\alpha'' \in (0, \alpha')$ 满足

$$f(x_k + \alpha' d_k) - f(x_k) = \alpha' \nabla f(x_k + \alpha'' d_k)^T d_k \quad (2)$$

由 (1), (2) 得

$$\nabla f(x_k + \alpha'' d_k)^T d_k = \sigma_1 \nabla f(x_k)^T d_k > \sigma_2 \nabla f(x_k)^T d_k$$


即 α'' 满足 Wolfe - Powell 条件, 由于 f 是连续可微的, 故必存在一个小的区间 $\alpha \in [a, b]$ 满足 Wolfe - Powell 条件(2.7).



用进退法实现Wolfe-Powell搜索：

逐渐变小以满足搜索条件的第一个条件

逐渐增大以满足搜索条件的第二个条件



具体实现如下：

步0: 若 $\alpha_k = 1$ 满足(2.7), 取若 $\alpha_k = 1$; 否则转下一步;


步2: 给定常数 $\beta > 0, \rho, \rho_1 \in (0,1)$. 令 $\alpha_k^{(0)}$ 是集合 $\{\beta \rho^j \mid (j \text{ 可正可负})\}$ 中满足第一个不等式的最大者. 令 $i = 0$;

步2: 若 $\alpha_k^{(i)}$ 满足第二个条件, 则取 $\alpha_k = \alpha_k^{(i)}$; 否则, 令 $\beta_k^{(i)} = \rho^{-1} \alpha_k^{(i)}$.

步3: 令 $\alpha_k^{(i+1)}$ 是集合

$$\{\alpha_k^{(i)} + \rho_1^j (\beta_k^{(i)} - \alpha_k^{(i)}), j = 0, 1, 2, \dots\}$$

中使得(2.7)第一个不等式成立的最大者, 令 $i = i + 1$, 转步2.



进退法计算Wolfe-Powell搜索的计算量比较大，但比较稳定，另一种常用的方法是二点插值法，计算简单，但不太稳定。
(感兴趣的同学，详看袁亚湘老师书:75-93页)


已知函数 φ ，及两点 α_1, α_2

插值法之一：已知两点 α_1, α_2 及函数值 $\varphi(\alpha_1), \varphi(\alpha_2)$, 导数 $\varphi'(\alpha_1)$

$$\alpha_{k+1} = \alpha_k - \frac{(\alpha_k - \alpha_{k-1})\varphi'_k}{2 \left[\varphi'_k - \frac{\varphi_k - \varphi_{k-1}}{\alpha_k - \alpha_{k-1}} \right]}$$

插值法之二：已知两点 α_1, α_2 及函数值 $\varphi(\alpha_1)$, 导数 $\varphi'(\alpha_1), \varphi'(\alpha_2)$

$$\alpha_{k+1} = \alpha_k - \frac{(\alpha_k - \alpha_{k-1})\varphi'_k}{\varphi'_k - \varphi'_{k-1}}$$



第三种重要的线性搜索：Goldstein搜索

$$f(x_k + \alpha d_k) \leq f(x_k) + \sigma_1 \alpha g_k^T d_k, \quad 0 < \sigma_1 < \frac{1}{2}$$

$$f(x_k + \alpha d_k) \geq f(x_k) + (1 - \sigma_1) \alpha g_k^T d_k$$

上机1

- 请用Matlab编程，实现黄金分割方法，采用这种方法，计算习题2的第1题

$f(x) = (x_1 - x_2)^2 + x_2^2$ 在点 $x = (0,1)^T$ 处沿着方向 $d = -(1,1)^T$ 的精确搜索步长。

- 再分别用Armijo型和Wolfe-Powell型线性搜索法确定上面的步长.请编写Matlab程序实现算法，分析参数对算法结果的影响.
- 比较上面3种方法，书写实验报告（含程序，计算结果的比较：迭代次数，最优目标值，总结和体会），本周日21:00前交。

课后：预习下降算法的收敛性和收敛速度定理的证明。

思考

- 二分法？如何采用二分法计算步长 α_k ？
- 能否用Matlab编程，实现二分法，或Fibonacci法？

作业：习题2： 5