

最优化理论与方法

第13讲

共轭梯度法

第5章 无约束问题算法(III)

— 共轭梯度法

第一节 二次函数极小值问题 的共轭方向法

第二节 非线性共轭梯度法

前面介绍的Newton法收敛较快，但须存储 n 阶矩阵，不适合求解大规模问题，而最速下降法虽然存储小但收敛慢。在这一章我们介绍存储小且收敛快的共轭梯度法。

首先介绍 共轭方向

及求解二次函数的共轭方向法.

\$5.1 二次函数极小值问题的共轭方向法

将下降算法用于求解二元二次函数

背景


$$f(x) = \frac{1}{2} x^T Q x + b^T x + c$$

的极小点, 这里 $x \in R^2$, $Q \in R^{2 \times 2}$ 对称正定,
 $b \in R^2, c \in R$.

给定初始点 x_0 及下降方向 p_0 . 线性搜索
后得点 x_1 满足

$$\nabla f(x_1)^T p_0 = 0$$

现在找方向 p_1 直接指向最优解 x^* ,
如何找呢?



(1) 方向 p_1 满足的条件

设从 x_1 沿 p_1 到 x^* 的最佳步长为 $\alpha_1 (\neq 0)$,
则有

$$x^* = x_1 + \alpha_1 p_1$$


因此 $\nabla f(x^*) = \nabla f(x_1) + \alpha_1 Q p_1$

由于 $\nabla f(x^*) = Q x^* + b = 0$

所以 $\nabla f(x_1) + \alpha_1 Q p_1 = 0$

等式左乘 p_0^T , 并注意到 $\alpha_1 \neq 0$, 得到

$$p_0^T Q p_1 = 0$$



这就是本章的核心： p_0 和 p_1 关于 Q 共轭

(2) 方向 p_1 的计算

由右图可知, p_1 可以表示成 p_0 与 $-\nabla f(x_1)$ 的线性组合. 令

$$p_1 = -\nabla f(x_1) + \beta p_0$$

由上面的条件得到


$$p_0^T Q p_1 = -p_0^T Q \nabla f(x_1) + \beta p_0^T Q p_0 = 0$$

由此解得

$$\beta = \frac{p_0^T Q \nabla f(x_1)}{p_0^T Q p_0}$$

所以

$$p_1 = -\nabla f(x_1) + \frac{p_0^T Q \nabla f(x_1)}{p_0^T Q p_0} p_0$$



从上面的 (1) 和 (2) 可以得出稍后要介绍的共轭方向法或共轭梯度法的基本原理

共轭方向的定义

考察二次函数极小化问题

$$\min f(x) = \frac{1}{2} x^T Q x + q^T x \quad (5.2)$$

其中 Q 是 n 阶对称正定矩阵, q 为 n 维常量

定义5.1.1 设 $A \in R^{n \times n}$ 对称正定, d_1, d_2, \dots, d_m 是 R^n 中非零向量. 若

$$d_i^T A d_j = 0, \quad \forall i, j, i \neq j$$

则称向量组 d_1, d_2, \dots, d_m 关于矩阵 A 相互共轭.

若 $Q = I$ ，向量共轭就是正交，所以共轭是正交的推广。

并且共轭向量组也是线性无关的。即有

定理5.1.1 设 $A \in R^{n \times n}$ 对称正定， d_1, d_2, \dots, d_n 关于矩阵 A 相互共轭，则向量组 d_1, d_2, \dots, d_n 线性无关。

推论 在 R^n 中，相互共轭的向量组的向量个数不超过 n

利用共轭方向,我们提出求二次函数(5.2)的极小值问题的共轭方向法

思想

从某个初始点 x_0 出发,依次沿关于 Q 共轭的 n 个方向 d_0, d_1, \dots, d_{n-1} 进行精确搜索

$$x_0 \xrightarrow[\alpha_0]{d_0} x_1 \xrightarrow[\alpha_1]{d_1} x_2 \xrightarrow[\alpha_2]{d_2} \cdots \xrightarrow[\alpha_{n-1}]{d_{n-1}} x_n$$

即令

$$x_{k+1} = x_k + \alpha_k d_k, \quad k = 0, 1, 2, \dots, n-1$$

其中 α_k 满足:

$$f(x_k + \alpha_k d_k) = \min_{\alpha \in R} f(x_k + \alpha d_k)$$

注意: 这里的搜索是在整个实数轴上进行,因为共轭方向不一定是下降方向

下面的定理说明了共轭方向法如何求出解

定理5.1.2 设函数 f 由(5.2)给出, 非零向量组 d_0, d_1, \dots, d_{n-1} 关于矩阵 Q 相互共轭. $\forall x_0 \in R^n$, 设迭代格式

$$x_{k+1} = x_k + \alpha_k d_k, k = 0, 1, \dots, n-1$$

其中步长 α_k 由精确搜索计算. 则

$$\nabla f(x_{k+1})^T d_j = 0, \quad \forall 0 \leq j < k+1$$

且 x_{k+1} 是 f 在线性流形

$$S_k = \left\{ x = x_0 + \sum_{i=0}^k \beta_i d_i \mid \beta_i \in R, i = 0, 1, 2, \dots, k \right\}$$

中的极小点. 特别, $x_n = x^* = -Q^{-1}q$ 是问题(5.2)的唯一极小点.

该定理称为子空间扩展定理

定理表明共轭方向法具有二次终止性

定理的证明：分两步

先证第一部分： $\nabla f(x_{k+1})^T d_j = 0, \forall j < k + 1$

若 $j = k$, 由精确搜索, 显然有: $\nabla f(x_{k+1})^T d_k = 0$

$0 \leq \forall j < k$, 由于

$$\begin{aligned}\nabla f(x_{k+1}) &= \nabla f(x_k) + \alpha_k Q d_k = \nabla f(x_{k-1}) + \alpha_k Q d_k + \alpha_{k-1} Q d_{k-1} \\ &= \dots\dots\end{aligned}$$

$$= \nabla f(x_{j+1}) + \sum_{i=j+1}^k \alpha_i Q d_i,$$

故由共轭性得

$$d_j^T \nabla f(x_{k+1}) = \underbrace{d_j^T \nabla f(x_{j+1})}_0 + \sum_{i=j+1}^k \underbrace{\alpha_i d_j^T Q d_i}_0 = 0 + 0 = 0$$

精确搜索

共轭性

再证第二部分

$\forall x \in S_k$ 且 $x \neq x_{k+1}$, 则

$$x = x_0 + \sum_{j=0}^k \beta_j d_j$$

由于
$$x_{k+1} = x_0 + \sum_{j=0}^k \alpha_j d_j$$

所以
$$x - x_{k+1} = \sum_{j=0}^k (\beta_j - \alpha_j) d_j$$

由泰勒公式得：

$$\begin{aligned} f(x) &= f(x_{k+1}) + \nabla f(x_{k+1})^T (x - x_{k+1}) + \frac{1}{2} (x - x_{k+1})^T Q (x - x_{k+1}) \\ &= f(x_{k+1}) + \frac{1}{2} (x - x_{k+1})^T Q (x - x_{k+1}) > f(x_{k+1}) \end{aligned}$$

所以 x_{k+1} 是 f 在 S_k 上极小点

x_{k+1} 是 f 在线性流形

$$S_k = \{x = x_0 + \sum_{i=0}^k \beta_i d_i \mid \beta_i \in R, i = 0, 1, 2, \dots, k\}$$

中的极小点.

共轭方向的计算

共轭方向可用类似于 Gram - Schmit 正交化过程来产生

算法5.1 (Gram - Schmit 共轭化过程)

步0 给定线性无关向量组: $p_0, p_1, \dots, p_{n-1} \in R^n$,

令 $d_0 = p_0, k := 0$;

步1 计算

$$d_{k+1} = p_{k+1} - \sum_{j=0}^k \frac{d_j^T Q p_{k+1}}{d_j^T Q p_j} d_j, \quad (5.5)$$

步2 若 $k = n - 2$, 则停止, 否则, 令 $k := k + 1$, 转步1.

容易验证, 由算法5.1产生的向量组 $d_0, d_1, \dots, d_{n-1} \in R^n$

关于矩阵 Q 相互共轭

考虑 $Ax=b$

1 $r_k = Ax_k - b.$

为保证 p_k 与 p_{k-1} 共轭, 该如何选取 β_k ?

3 $p_k = -r_k + \beta_k p_{k-1},$

上式两边同乘以 $p_{k-1}^T A$, 得到

采用下降迭代方法

$$\beta_k = \frac{r_k^T A p_{k-1}}{p_{k-1}^T A p_{k-1}}.$$

2

5 $x_{k+1} = x_k + \alpha_k p_k,$

步长采用精确线搜索法, 即

$$\alpha_k = -\frac{r_k^T p_k}{p_k^T A p_k};$$

4

CG算法1

Given x_0 ;

Set $r_0 \leftarrow Ax_0 - b$, $p_0 \leftarrow -r_0$, $k \leftarrow 0$;

while $r_k \neq 0$

$$\alpha_k \leftarrow -\frac{r_k^T p_k}{p_k^T A p_k};$$

$$x_{k+1} \leftarrow x_k + \alpha_k p_k;$$

$$r_{k+1} \leftarrow Ax_{k+1} - b;$$

$$\beta_{k+1} \leftarrow \frac{r_{k+1}^T A p_k}{p_k^T A p_k};$$

$$p_{k+1} \leftarrow -r_{k+1} + \beta_{k+1} p_k;$$

$$k \leftarrow k + 1;$$

end (while)

CG算法1的收敛性和性质

- 假设该算法第 k 步迭代得到的不是方程的解 x^* ，则有下面性质，并且迭代序列 $\{x_k\}$ 最多 n 步收敛到解 x^*

$$r_k^T r_i = 0, \quad \text{for } i = 0, 1, \dots, k-1,$$

$$\text{span}\{r_0, r_1, \dots, r_k\} = \text{span}\{r_0, Ar_0, \dots, A^k r_0\},$$

$$\text{span}\{p_0, p_1, \dots, p_k\} = \text{span}\{r_0, Ar_0, \dots, A^k r_0\},$$

$$p_k^T A p_i = 0, \quad \text{for } i = 0, 1, \dots, k-1.$$

CG算法2（实际问题常使用）

Algorithm 5.2 (CG).

Given x_0 ;

Set $r_0 \leftarrow Ax_0 - b$, $p_0 \leftarrow -r_0$, $k \leftarrow 0$;

while $r_k \neq 0$

$$\alpha_k \leftarrow \frac{r_k^T r_k}{p_k^T A p_k};$$

$$x_{k+1} \leftarrow x_k + \alpha_k p_k;$$

$$r_{k+1} \leftarrow r_k + \alpha_k A p_k;$$

$$\beta_{k+1} \leftarrow \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k};$$

$$p_{k+1} \leftarrow -r_{k+1} + \beta_{k+1} p_k;$$

$$k \leftarrow k + 1;$$

end (while)

收敛性结果

- 如果矩阵**A**只有**r**个不同的特征值，那么**CG**迭代最多**r**步迭代到解。

- 如果**A**有特征值 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ ，那么

$$\|x_{k+1} - x^*\|_A^2 \leq \left(\frac{\lambda_{n-k} - \lambda_1}{\lambda_{n-k} + \lambda_1} \right)^2 \|x_0 - x^*\|_A^2.$$

$$\kappa(A) = \|A\|_2 \|A^{-1}\|_2 = \lambda_n / \lambda_1.$$

$$\|x_k - x^*\|_A \leq 2 \left(\frac{\sqrt{\kappa(A)} - 1}{\sqrt{\kappa(A)} + 1} \right)^k \|x_0 - x^*\|_A.$$





Figure 5.3 Two clusters of eigenvalues.



5个大的特征值
其余聚点为1

预处理

$$\hat{x} = Cx.$$

$$\hat{\phi}(\hat{x}) = \frac{1}{2}\hat{x}^T(C^{-T}AC^{-1})\hat{x} - (C^{-T}b)^T\hat{x}.$$

$$(C^{-T}AC^{-1})\hat{x} = C^{-T}b,$$

应用Algorithm 5.2解上面问题，再转化成x变量，得到预处理共轭梯度方法

预处理的目的是，使矩阵的条件数变小

Algorithm 5.3 (Preconditioned CG).

Given x_0 , preconditioner M ;

Set $r_0 \leftarrow Ax_0 - b$;

Solve $My_0 = r_0$ for y_0 ;

Set $p_0 = -y_0, k \leftarrow 0$;

while $r_k \neq 0$

$$\alpha_k \leftarrow \frac{r_k^T y_k}{p_k^T A p_k}; \quad (5.39a)$$

$$x_{k+1} \leftarrow x_k + \alpha_k p_k; \quad (5.39b)$$

$$r_{k+1} \leftarrow r_k + \alpha_k A p_k; \quad (5.39c)$$

$$\text{Solve } M y_{k+1} = r_{k+1}; \quad (5.39d)$$

$$\beta_{k+1} \leftarrow \frac{r_{k+1}^T y_{k+1}}{r_k^T y_k}; \quad (5.39e)$$

$$p_{k+1} \leftarrow -y_{k+1} + \beta_{k+1} p_k; \quad (5.39f)$$

$$k \leftarrow k + 1; \quad (5.39g)$$

end (while)

总 结：

1. 共轭梯度法的优点是不需要存储矩阵，只需存储矩阵乘向量，存储小，计算简单，适合求解大规模线性方程组和二次函数极小化问题.
2. 至多 n 步迭代收敛到最优解。预处理可以加速
3. 采用精确搜索， 初始方向必须选择最速下降方向.

作业

- 习题5（李董辉书）
2, 4
- 推导《Numerical Optimization的Algorithm 5.3
- 编程练习：Exercise 5.1. 实现Algorithm5.2