

最优化理论和方法

约束问题的最优性条件

第九章 约束问题的最优性条件

第一节 可行方向

第二节 约束问题最优性条件

考虑一般约束问题：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i \in I = \{1, 2, \dots, m_1\} \\ & h_j(x) = 0, j \in E = \{m_1 + 1, \dots, m\} \end{aligned} \tag{9.1}$$


可行域： $D = \{x : g_i(x) \geq 0, i \in I; h_j(x) = 0, j \in E\}$

这里我们假设函数 f, g_i, h_j 连续可微

显然可行域 D 为闭集.

非光滑无约束优化有时可转化为 光滑的约束优化问题

$$f(x) = \max(x^2, x),$$



$$\min t \quad \text{s.t.} \quad t \geq x, \quad t \geq x^2.$$

第一节 可行方向

在第二章我们提到,约束问题问题的最优性条件有四个,为导出这些条件,我们需做一些准备工作

首先,我们需介绍与约束条件有关的可行方向.

定义9.1.1 设 $x \in D, d \in R^n$.若存在数 $\delta > 0$,使得

$$x + \alpha d \in D, \forall \alpha \in (0, \delta],$$

则称 d 是 D 在 x 处的一个可行方向.

记 x 处所有可行方向的集合为 $FD(x, D)$

若记 x 处函数 f 的所有下降方向

集合为 $GD(x)$


容易看出,如果 x^* 是(9.1)的最优

解, 则在该点不存在既下降又

可行的方向, 即

$$GD(x^*) \cap FD(x^*, D) = \emptyset$$

该条件称为几何最优性条件



我们的目的是将几何最优性条件转化为便于计算的代数最优性条件. 这要求GD(x)和FD(x, D)的代数条件

$\forall x \in D$, 对于GD(x), 我们有

$$\text{GD}(x) \supseteq \{d \in R^n \mid \nabla f(x)^T d < 0\}$$

但可行方向集FD(x, D)的计算是困难的

事实上: 对于 $d \in R^n$, 类似于GD(x)的计算

等式 $h_j(x) = 0$: $\nabla h_j(x)^T d > 0$ 不是可行方向

$\nabla h_j(x)^T d < 0$ 不是可行方向

$\nabla h_j(x)^T d = 0$ 包含可行方向

不等式 $g_i(x) = 0$: $\nabla g_i(x)^T d \geq 0$ 是可行方向

不等式 $g_i(x) > 0$: $\forall 0 \neq d \in R^n$ 是可行方向

由上面分析可知： $\forall d \in \text{FD}(x, D)$, 则有

$$\begin{cases} \nabla h_j(x)^T d = 0, & \forall j \in E \\ \nabla g_i(x)^T d \geq 0, & \forall i \in I \text{ 且 } g_i(x) = 0 \end{cases}$$

但反之不一定成立.

为了方便起见, 记

$$\text{LFD}(x, D) = \left\{ d \in R^n \left| \begin{array}{l} \nabla h_j(x)^T d = 0, \quad \forall j \in E \\ \nabla g_i(x)^T d \geq 0, \quad \forall i \in I \text{ 且 } g_i(x) = 0 \end{array} \right. \right\}$$

显然 $\text{FD}(x, D) \subseteq \text{LFD}(x, D)$

为了更好地描述 $\text{FD}(x, D)$, 我们去掉 $\text{LFD}(x, D)$ 中的某些"多余"的向量, 而得到一个新的方向集合. 具体如下:

定义9.1.2 设 $x \in D, d \in R^n$. 若存在向量序列 $\{d_k\}$ 和正数序列 $\{\delta_k\}$,使得


$$x + \delta_k d_k \in D, \quad \forall k$$

且 $\lim_{k \rightarrow \infty} d_k = d$ 和 $\lim_{k \rightarrow \infty} \delta_k = 0$


则称 d 是 D 在 x 处的一个序列可行方向, D 在 x 处的所有序列可行方向的集合记作 $\text{SFD}(x,D)$.

令 $x_k = x + \delta_k d_k$, 由定义9.1.2知, $\{x_k\} \subset D$.

为理解序列可行方向,我们来看看它的几何解释:



(a) 点 x 在 D 内部



(b) 点 x 在 D 的边界上

序列可行方向实际上就是可行方向

序列可行方向包含可行方向和边界的切线方向

显然, $\text{FD}(x, D) \subseteq \text{SFD}(x, D)$ (只需取 $d_k = d$)

可行方向必是序列可行方向, 但反之不然.

Tangent cone(切锥)

Definition 12.2.

The vector d is said to be a tangent (or tangent vector) to Ω at a point x if there are a feasible sequence $\{z_k\}$ approaching x and a sequence of positive scalars $\{t_k\}$ with $t_k \rightarrow 0$ such that

$$\lim_{k \rightarrow \infty} \frac{z_k - x}{t_k} = d. \quad (12.29)$$

The set of all tangents to Ω at x^* is called the tangent cone and is denoted by $T_\Omega(x^*)$.

定义9.1.2 设 $x \in D, d \in R^n$. 若存在向量序列 $\{d_k\}$ 和正数序列 $\{\delta_k\}$, 使得

$$x + \delta_k d_k \in D, \quad \forall k$$

且 $\lim_{k \rightarrow \infty} d_k = d$ 和 $\lim_{k \rightarrow \infty} \delta_k = 0$

则称 d 是 D 在 x 处的一个序列可行方向. D 在 x 处的所有序列可行方向的集合记作 $\text{SFD}(x, D)$.

定理9.1.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解, 则

$$\nabla f(x^*)^T d \geq 0, \quad \forall d \in \text{SFD}(x^*, D) \text{ 必要条件}$$

证明: 因为 x^* 是局部最优解, 由定义, 必存在邻域 $N(x^*)$, 使得理表明最优解处的, 任何序列可行方向不可能是目标函数, 在该点处的下降方向. $\forall d \in \text{SFD}(x^*, D)$, 存在可行点序列 $\{x_k\}$ 满足

$$x_k = x^* + \delta_k d_k \rightarrow x^*$$

其中 $\delta_k \rightarrow 0, d_k \rightarrow d$. 所以, 当 k 充分大时, $x_k \in N(x^*)$.

$$\begin{aligned} \text{故 } f(x^*) &\leq f(x_k) = f(x^* + \delta_k d_k) \\ &= f(x^*) + \delta_k \nabla f(x^*)^T d_k + o(\|\delta_k d_k\|) \end{aligned}$$

在上式两端除以 δ_k , 然后令 $\delta_k \rightarrow 0$, 取极限即可得

$$\nabla f(x^*)^T d \geq 0$$

类似于无约束问题的极值条件,进一步我们有关于SFD的最优解的充分条件:

定理9.1.2 设 $x^* \in D$ 且满足

$$\nabla f(x^*)^T d > 0, \quad \forall 0 \neq d \in \text{SFD}(x^*, D)$$

则 x^* 问题(9.1)的一个严格局部最优解.

证明: 构造性的反证法

若 x^* 不是问题(9.1)的最优解,则必定存在序列 $\{x_k\} \subset D$,使得

$$f(x^*) \geq f(x_k) \text{ 且 } x_k \rightarrow x^* \quad (x_k \neq x^*)$$

令 $d_k = \frac{x_k - x^*}{\|x_k - x^*\|}$, $\delta_k = \|x_k - x^*\|$. 则 $x_k = x^* + \delta_k d_k$ 且 $\delta_k \rightarrow 0$.

由于序列 $\{d_k\}$ 有界,必存在收敛的子列.不妨设 $d_k \rightarrow d \neq 0$.

由 $\text{SFD}(x^*, D)$ 的定义可知,所构造的向量 $d \in \text{SFD}(x^*, D)$.

然而,由

$$\begin{aligned} f(x^*) &\geq f(x_k) = f(x^* + \delta_k d_k) \\ &= f(x^*) + \delta_k \nabla f(x^*)^T d_k + o(\|\delta_k d_k\|) \end{aligned}$$

在上式两端除以 δ_k ,然后令 $\delta_k \rightarrow 0$,取极限即可得

$$\nabla f(x^*)^T d \leq 0$$

这与定理假设矛盾.因此 x^* 是问题(9.1)的一个严格局部最优解. 证毕

定理表明:若可行点 x^* 处的所有序列可行方向都是目标函数 f 在该点处的上升方向,则 x^* 必定是严格局部最优解.

我们注意到：由于序列可行方向集 $SFD(x^*, D)$ 没有便于计算的公式,上面两个定理给出的最优解的判别条件仅具有理论意义,并没有实际的应用价值.

为将上面给出的最优解的判别条件代数化,我们需研究可行方向集的代数表示.

策略：将 $SFD(x^*, D)$ 放大到某一具有代数表示式的方向集——从前面介绍的 $LFD(x, D)$ （具有代数表示）得到启示：

将约束条件线性化而得到某种可行方向.



线性化可行方向

在前面,我们已经看到: $\forall x \in D$, 在 x 处的可行方向 d 的要求与约束有关,具体如下:

对等式 $h_j(x) = 0, \forall j \in E$:

$$\text{要求 } \nabla h_j(x)^T d = 0$$

对不等式: $g_i(x) \geq 0, \forall i \in I$, 分两种情形:

当 $g_i(x) = 0$ 时, 要求 $\nabla g_i(x)^T d \geq 0$

当 $g_i(x) > 0$ 时, 则对 $d \neq 0$ 无要求

基于上面的分析,我们引入如下的定义:

定义 对 $x \in D$, 记索引集合


$$I(x) = \{i \in I \mid g_i(x) = 0\}, A(x) = E \cup I(x)$$

称集合 $A(x)$ 为可行点 x 处的有效集或积极集.

若 $i \in I(x)$ 或 $j \in E$, 称相应的约束为 x 处的有效约束, 即有

$$g_i(x) = 0 \text{ 或 } h_i(x) = 0$$

其它约束称为 x 处的非有效约束或无效约束.



如图：观察不同点处
的有效约束

D 内的点没有有效约束
仅边界上的点存在有效约束

总结： x 处的有效约束是指该约束对该点处的可行方向起限制作用,反之无效约束即对该点处的可行方向没有任何影响.不同的可行点一般有不同的有效约束.

所有存在有效约束的点构成可行域的边界.


例9.1.1 考察如下约束问题：

$$\min f(x) = x_1^2 + x_2^2$$

$$s.t. \quad x_1 + 2x_2 \leq 8$$

$$0 \leq x_1 \leq 4$$

$$0 \leq x_2 \leq 3$$



标 $g_1(x) = 8 - x_1 - 2x_2 \geq 0$

准 $g_2(x) = x_1 \geq 0$

$$g_3(x) = 4 - x_1 \geq 0$$

形 $g_4(x) = x_2 \geq 0$

式 $g_5(x) = 3 - x_2 \geq 0$

$$I(x^{(0)}) = \{2, 4\}$$

$$I(x^{(1)}) = \{1, 3\}$$

利用有效集,我们给出下面线性化可行方向的定义:

定义9.1.3 设 $x \in D$, 集合

$$\text{LFD}(x, D) = \left\{ d \in R^n \left| \begin{array}{l} d^T \nabla g_i(x) \geq 0, \forall i \in I(x) \\ d^T \nabla h_j(x) = 0, \forall j \in E \end{array} \right. \right\}$$

中的向量 d 称为 D 在 x 处的线性化可行方向.

线性化可行方向只与有效集有关,且具有线性表达式,
便于计算.而且下面的命题成立:

命题 设 $x \in D$, 则

$$\text{FD}(x, D) \subseteq \text{SFD}(x, D) \subseteq \text{LFD}(x, D)$$

回忆：定理9.1.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解,则

$$\nabla f(x^*)^T d \geq 0, \quad \forall d \in \text{SFD}(x^*, D)$$

证明：只需证第二个关系. $\forall d \in \text{SFD}(x, D)$, 则存在

$$d_k \rightarrow d, \delta_k \rightarrow 0, \text{使得 } x + \delta_k d_k \in D. \text{ 故}$$

$\forall i \in I(x)$, 由于 $g_i(x) = 0$, 因此

$$\delta_k \nabla g_i(x)^T d_k + o(\|\delta_k d_k\|) \geq 0$$

$\forall j \in E$, 由于 $h_j(x) = 0$, 因此

$$h_j(x + \delta_k d_k) = \delta_k \nabla h_j(x)^T d_k + o(\|\delta_k d_k\|) = 0$$

在上面两式的两端同时处以 δ_k , 然后令 $k \rightarrow \infty$, 即有

$$\nabla g_i(x)^T d \geq 0 \text{ 和 } \nabla h_j(x)^T d = 0, \text{ 即 } d \in \text{LFD}(x, D)$$

注意：尽管 $\text{LFD}(x, D)$ 具有代数表示, 但上面的命题表明

$\text{SFD}(x, D)$ 是 $\text{LFD}(x, D)$ 的一个子集, 因此还不能用

$\text{LFD}(x, D)$ 替换定理 9.1.1 中的 $\text{SFD}(x, D)$

定理9.1.3 若 $g_i(x), i \in I, h_j(x), j \in E$ 都是线性函数, 则

$$\text{FD}(x, D) = \text{SFD}(x, D) = \text{LFD}(x, D)$$

证明: $\forall x \in D$, 由前面的命题知, 现在只需证

$$\text{LFD}(x, D) \subseteq \text{FD}(x, D).$$

令 $g_i(x) = a_i^T x + b_i, \quad i \in I$

$$h_j(x) = a_j^T x + b_j, \quad j \in E$$

对 $\forall d \in \text{LFD}(x, D)$, 则有 d 满足

$$\begin{cases} a_j^T d = 0, j \in E \\ a_i^T d \geq 0, i \in I(x) \end{cases}$$

分三种情形讨论:

(1) $\forall j \in E$, 由于 $h_j(x) = a_j^T x + b_j = 0$, 则对任意的 $\alpha \geq 0$,

$$h_j(x + \alpha d) = a_j^T (x + \alpha d) + b_j = a_j^T x + b_j + \alpha a_j^T d = 0,$$

(2) $\forall i \in I(x)$, 由于 $g_i(x) = a_i^T x + b_i = 0$, 则对任意的 $\alpha \geq 0$,

$$g_i(x + \alpha d) = a_i^T (x + \alpha d) + b_i = a_i^T x + b_i + \alpha a_i^T d \geq 0,$$

(3) $\forall i \in I \setminus I(x)$, 由于 $g_i(x) = a_i^T x + b_i > 0$, 即 $-a_i^T x - b_i < 0$

则要使

$$g_i(x + \alpha d) = a_i^T (x + \alpha d) + b_i = a_i^T x + b_i + \alpha a_i^T d \geq 0,$$

若 $a_i^T d \geq 0$, 显然上式对任意 $\alpha \geq 0$ 成立,

若 $a_i^T d < 0$, 则要求 $\alpha \leq \frac{-a_i^T x - b_i}{a_i^T d}$, 此时我们令

$$\bar{\alpha} = \min \left\{ \frac{-a_i^T x - b_i}{a_i^T d} \mid i \in I \setminus I(x), a_i^T d < 0 \right\}$$

则对任意的 $i \in I \setminus I(x)$, 我们有

$$a_i^T x + b_i + \alpha a_i^T d \geq 0, \forall \alpha \in (0, \bar{\alpha})$$

综上所述, 我们证明了: $d \in \text{FD}(x, D)$.

证毕

除约束函数是线性函数外,人们更多研究的是对一般的非线性函数在什么情况下满足条件:

$$\text{SFD}(x, D) = \text{LFD}(x, D)$$

上面的条件首先由Abadie (1972年)提出,称之为Abadie约束品性 (Constraint Qualification), 简称为ACQ
约束品性对研究约束问题的最优性条件是非常重要的, ACQ是最基本的约束品性. 除此之外, 人们研究了一些较强的约束品性.

定义9.1.4 设 $x \in D$, 若向量组

$$\{ \nabla g_i(x), \nabla h_j(x), i \in I(x), j \in E \}$$

线性无关, 则称在 x 处线性无关约束品性成立, 简称为在 x 处LICQ (Linear independence Constraint Qualification) 成立.

引理9.1.1 设 $x \in D$, 若向量组

$$\{\nabla g_i(x), \nabla h_j(x), i \in I(x), j \in E\}$$

线性无关, 则

$$\text{SFD}(x, D) = \text{LFD}(x, D)$$

证明：有点难, 还是省略吧！感兴趣的同学自己琢磨。

由引理9.1.1知： $\text{LICQ} \Rightarrow \text{ACQ}$

现在我们再回头看看定理9.1.1,

定理9.1.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解, 则

$$\nabla f(x^*)^T d \geq 0, \quad \forall d \in \text{SFD}(x^*, D)$$

发现了什么？

ACQ成立
↓
LFD(x, D)

定理9.1.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解, 则

$$\nabla f(x^*)^T d \geq 0, \quad \forall d \in \text{SFD}(x^*, D)$$

如果我们将 $\text{SFD}(x, D)$ 换成 $\text{LFD}(x, D)$, 那么定理9.1.1可以等价地描述为:

定理9.1.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解, 则关于向量 $d \in R^n$ 的线性系统:

$$\begin{cases} \nabla f(x^*)^T d < 0 \\ \nabla g_i(x^*)^T d \geq 0, \quad i \in I(x^*) \\ \nabla h_j(x^*)^T d = 0, \quad j \in E \end{cases}$$

无解.

思考: Farkas 定理还有谁记得? 又等价于什么? 上面的线性系统无解又等价于什么?

Farkas定理的推论： 设 A 为 $m \times n$ 矩阵, B 为 $p \times n$ 矩阵 $c \in R^n$, 则

$$Ax \leq 0, Bx = 0, c^T x > 0 \text{ 无解} \Leftrightarrow A^T y + B^T z = c, y \geq 0 \text{ 有解}$$

引理9.1.2 不等式 $\nabla f(x)^T d \geq 0$ 对所有 $d \in \text{LFD}(x, D)$ 成立, 则存在 $\lambda_i \geq 0, i \in I(x); \mu_j, j \in E$, 使得

$$\nabla f(x) - \sum_{i \in I(x)} \lambda_i \nabla g_i(x) - \sum_{j \in E} \mu_j \nabla h_j(x) = 0$$

该引理可以由Farkas定理的推论直接写出

第二节 约束问题的最优性条件

1、一阶必要条件

定义函数 $L: R_{n+m} \rightarrow R$:

$$\begin{aligned} L(x, \lambda, \mu) &= f(x) - \lambda^T g_I(x) - \mu^T h_E(x) \\ &= f(x) - \sum_{i \in I} \lambda_i g_i(x) - \sum_{j \in E} \mu_j h_j(x) \end{aligned}$$

该函数称为问题 (9.1) 的Lagrange函数, 其中 $\lambda \in R^{m_1}$, $\mu \in R^{m-m_1}$ 称为Lgrange乘子.

$$\nabla_x L(x, \lambda, \mu) = \nabla f(x) - \sum_{i \in I} \lambda_i \nabla g_i(x) - \sum_{j \in E} \mu_j \nabla h_j(x)$$

$$\nabla_x^2 L(x, \lambda, \mu) = \nabla^2 f(x) - \sum_{i \in I} \lambda_i \nabla^2 g_i(x) - \sum_{j \in E} \mu_j \nabla^2 h_j(x)$$

定理9.1.1的改进版：

定理9.2.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解, 如果

$$\text{SFD}(x^*, D) = \text{LFD}(x^*, D) \quad (9.6)$$

则存在Lagrange乘子向量： $\lambda^* \in R^{m_1}, \mu^* \in R^{m-m_1}$

使得

$$\begin{cases} \nabla_x L(x^*, \lambda^*, \mu^*) = 0 \\ h_j(x^*) = 0, j \in E \\ g_i(x^*) \geq 0, \lambda_i^* \geq 0, \lambda_i^* g_i(x^*) = 0, i \in I \end{cases} \quad (9.7)$$

这里,

互补松弛条件

$$\nabla_x L(x^*, \lambda^*, \mu^*) = \nabla f(x^*) - \sum_{i \in I} \lambda_i^* \nabla g_i(x^*) - \sum_{j \in E} \mu_j^* \nabla h_j(x^*)$$

(9.7)称为问题(9.1)的一阶必要条件—K-K-T条件
满足(9.7)的点 x^* 称为问题(9.1)的一个KKT点.

由于(9.7)中无需已知 $I(x^*)$, (9.7)除能用于最优解的判别,
而且能用来计算KKT点—可能的最优解.

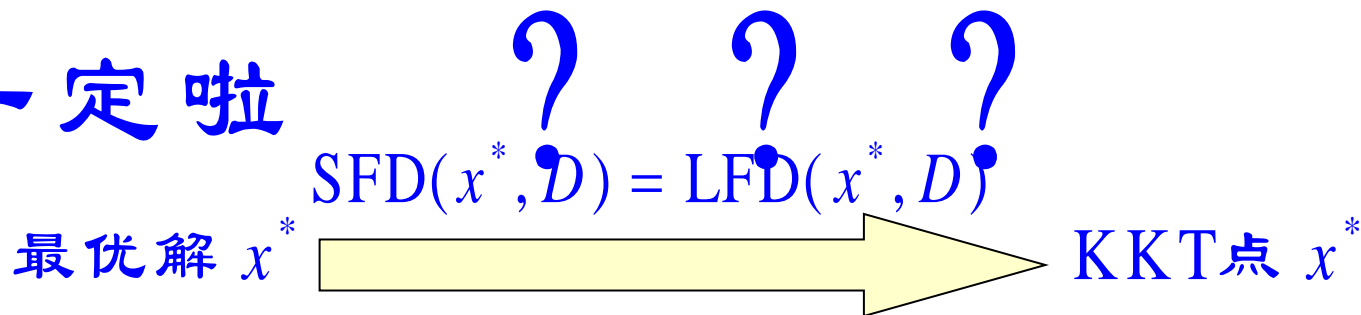
约束问题的KKT点 类似于无约束问题的驻点.

思考

若函数可导, 无约束问题的极值点一定是驻点,

请问约束问题的局部最优解一定是KKT点吗??

不一定啦



一般的KKT条件 (KKT系统)

$$\begin{cases} \nabla_x L(x, \lambda, \mu) = 0 \\ h_j(x) = 0, j \in E \\ g_i(x) \geq 0, \lambda_i \geq 0, \lambda_i g_i(x) = 0, i \in I \end{cases} \quad (9.7b)$$

或向量形式：

$$H(x, \lambda, \mu) = \begin{pmatrix} \nabla_x L(x, \lambda, \mu) \\ h_E(x) \\ \min\{\lambda_I, g_I(x)\} \end{pmatrix} = 0 \quad (9.7c)$$

其中向量函数的极小值按分量进行比较。

利用KKT条件，我们可以计算约束问题的KKT点

一般来说, KKT点的判别用定理9.1.1改进版的条件, 即

$$\begin{cases} \nabla f(x^*) - \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*) - \sum_{j \in E} \mu_j^* \nabla h_j(x^*) = 0 \\ \lambda_i^* \geq 0, i \in I(x^*) \end{cases}$$

而KKT点的计算则采用KKT系统 (9.7b)

例 9.2.1 已知 $\bar{x} = (3, 1)^T$ 是下列问题的最优解

$$\begin{cases} \min & f(x) = (x_1 - 7)^2 + (x_2 - 3)^2 \\ \text{s. t.} & g_1(x) = 10 - x_1^2 - x_2^2 \geq 0 \\ & g_2(x) = x_1 - x_2 - 2 \leq 0 \\ & g_3(x) = x_2 \geq 0 \end{cases}$$

试问 \bar{x} 是KKT点吗?

解： 经验证： $I(\bar{x}) = \{1, 2\}$, 计算目标函数及有效约束在点 \bar{x} 处的梯度为

$$\nabla f(\bar{x}) = \begin{pmatrix} -8 \\ -4 \end{pmatrix}, \nabla g_1(x) = \begin{pmatrix} -6 \\ -2 \end{pmatrix}, \nabla g_2(x) = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

显然, 有效约束的梯度 $\nabla g_1(\bar{x}), \nabla g_2(\bar{x})$ 线性无关, 从而

$$\text{SFD}(\bar{x}, D) = \text{LFD}(\bar{x}, D)$$

因此, 最优解一定是KKT点. 事实上, 令

$$\begin{pmatrix} -8 \\ -4 \end{pmatrix} - \lambda_1 \begin{pmatrix} -6 \\ -2 \end{pmatrix} - \lambda_2 \begin{pmatrix} -1 \\ -1 \end{pmatrix} = \begin{cases} \min & f(x) = (x_1 - 7)^2 + (x_2 - 3)^2 \\ \text{s. t.} & g_1(x) = 10 - x_1^2 - x_2^2 \geq 0 \\ & g_2(x) = x_1 - x_2 - 2 \leq 0 \\ & g_3(x) = x_2 \geq 0 \end{cases}$$

即得
$$\begin{cases} 6\lambda_1 + \lambda_2 - 8 = 0 \\ 2\lambda_1 + \lambda_2 - 4 = 0 \end{cases}$$

则方程组存在非负解, $\lambda_1 = 1, \lambda_2 = 2$, 即 \bar{x} 是KKT点.

例 9.2.2 已知约束问题


$$\min f(x) = -x_2$$

$$s.t. \quad g_1(x) = -2x_1 + (2 - x_2)^3 \geq 0$$

$$g_2(x) = x_1 \geq 0$$

请问 $\bar{x} = (0, 2)^T$ 是 KKT 点吗,

是最优解吗 ?



\bar{x} 是最优解吗 ?

解: $I(\bar{x}) = \{1, 2\}$, 即两个约束都是有效约束.

$$\nabla f(\bar{x}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \quad \nabla g_1(\bar{x}) = \begin{pmatrix} -2 \\ 0 \end{pmatrix}, \quad \nabla g_2(\bar{x}) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

是

显然, $\nabla g_1(\bar{x}), \nabla g_2(\bar{x})$ 线性相关. 令

$$\begin{pmatrix} 0 \\ -1 \end{pmatrix} - \lambda_1 \begin{pmatrix} -2 \\ 0 \end{pmatrix} - \lambda_2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = 0$$

$\nabla f(\bar{x}) \perp \nabla g_1(\bar{x}), \nabla f(\bar{x}) \perp \nabla g_2(\bar{x}),$

$\nabla f(\bar{x})$ 不能用 $\nabla g_1(\bar{x}), \nabla g_2(\bar{x})$ 的正

线性组合表示

方程组无解, 见图, 故 \bar{x} 不是 KKT 点

例9.2.3 求下列约束问题的 KKT 点

$$\min \quad f(x) = x_1$$

$$s.t. \quad g(x) = -(x_1 - 4)^2 - x_2^2 + 16 \geq 0$$

$$h(x) = x_1^2 + (x_2 - 2)^2 - 4 = 0$$

解：该问题的KKT条件为：

$$\begin{cases} \begin{pmatrix} 1 \\ 0 \end{pmatrix} + \lambda \begin{pmatrix} 2(x_1 - 4) \\ 2x_2 \end{pmatrix} - \mu \begin{pmatrix} 2x_1 \\ 2(x_2 - 2) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ -(x_1 - 4)^2 - 2x_2^2 + 16 \geq 0 \\ x_1^2 + (x_2 - 2)^2 - 4 = 0 \\ \lambda \geq 0, \lambda[-(x_1 - 4)^2 - x_2^2 + 16] = 0 \end{cases}$$

解上面的KKT系统,得KKT点为:


$$\begin{pmatrix} x^{(1)} \\ \lambda_1 \\ \mu_1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 1/8 \end{pmatrix}, \quad \begin{pmatrix} x^{(2)} \\ \lambda_2 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} 8/5 \\ 16/5 \\ 3/40 \end{pmatrix}, \quad \begin{pmatrix} x^{(3)} \\ \lambda_3 \\ \mu_3 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \\ 0 \end{pmatrix}$$

由右图可知,

$x^{(1)}$ 是最优解,

$x^{(2)}$? 是最优解

$x^{(3)}$ 不是最优解



与无约束问题的一阶必要条件类似,对于凸规划,
KKT条件也是充分条件

定理9.2.4 设 f 是凸函数, $g_i(x), i \in I$ 是凹函数, $h_j(x), j \in E$ 是线性函数. 若在 x^* 处满足KKT条件(9.7), 则 x^* 是问题(9.1)的全局最优解.

证明: $\forall x \in D$, 由已知条件, 我们有

$$f(x) - f(x^*) \geq \nabla f(x^*)^T (x - x^*)$$

$$0 \leq g_i(x) = g_i(x) - g_i(x^*) \leq \nabla g_i(x^*)^T (x - x^*), i \in I(x^*)$$

$$0 = h_j(x) - h_j(x^*) = \nabla h_j(x^*)^T (x - x^*), j \in E$$

从而由KKT条件 (9.7) 得

$$\begin{aligned} f(x) - f(x^*) &\geq \nabla f(x^*)^T (x - x^*) \\ &= \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*)^T (x - x^*) + \sum_{j \in E} \mu_j^* \nabla h_j(x^*)^T (x - x^*) \geq 0 \end{aligned}$$

所以 x^* 是全局最优解.

2、二阶条件

设 $x^* \in D$ 是(9.1)的一个局部最优解. 为介绍其二阶条件, 我们首先看看前面介绍的定理9.1.1和定理9.1.2

定理9.1.1 设 $x^* \in D$ 是问题(9.1)的一个局部最优解, 则

$$\nabla f(x^*)^T d \geq 0, \quad \forall d \in \text{SFD}(x^*, D)$$

定理9.1.2 设 $x^* \in D$ 且满足

$$\nabla f(x^*)^T d > 0, \quad \forall 0 \neq d \in \text{SFD}(x^*, D)$$

则 x^* 问题(9.1)的一个严格局部最优解.

如果存在 $0 \neq d \in \text{SFD}(x^*, D)$, 使得

提示:

$$\nabla f(x^*)^T d = 0$$

会怎么样?

定理9.1.2失效

研究二阶条件的目的：当

$$\nabla f(x^*)^T d = 0, \quad 0 \neq d \in \text{SFD}(x^*, D) \quad (9.**)$$

时,最优解的判别条件.

假定在 x^* 处 $\text{SFD}(x^*, D) = \text{LFD}(x^*, D)$ 成立,则 x^* 是一个KKT点,即存在Lagrange 乘子 $\lambda_i^* \geq 0, i \in I, \mu_j^*, j \in E$ 满足KKT条件(9.7). 则

$$(9.**) \iff 0 \neq d \in \text{LFD}(x^*, D) \text{ 且}$$

$$0 = \nabla f(x^*)^T d = \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*)^T d + \sum_{j \in E} \mu_j^* \nabla h_j(x^*)^T d,$$

$$= \sum_{i \in I(x^*)} \lambda_i^* \nabla g_i(x^*)^T d$$

$$\iff \lambda_i^* d^T \nabla g_i(x^*) = 0, i \in I(x^*), \forall d \in \text{LFD}(x^*, D)$$

记 $z^* = (x^*, \lambda^*, \mu^*)$, 定义集合:

$$S(z^*) = \left\{ d \in \text{LFD}(x^*, D) \mid \lambda_i^* d^T \nabla g_i(x^*) = 0, i \in I(x^*) \right\}$$

称 $d \in S(z^*)$ 是 x^* 处的线性化零约束方向.

注意: 当(9.1)只有等式约束时: $S(z^*) = \text{LFD}(x^*, D)$

定理9.2.2 设 $f(x), g_i(x), h_j(x) (i \in I, j \in E)$ 二次连续可微, x^* 是(9.1)的一个局部最优解, 且在该点处LICQ成立.

则存在Lgrange乘子 $\lambda^* \in R^{m_1}, \mu^* \in R^{m-m_1}$ 满足(9.7) 且

$$d^T \nabla_x^2 L(z^*) d \geq 0, \quad \forall d \in S(z^*) \quad (9.8)$$

注意:

如果将定理中条件 LICQ 改成 ACQ,

定理结论不一定成立

定理9.2.3 设 $f(x), g_i(x), h_j(x) (i \in I, j \in E)$ 二次连续可微. 设 $x^* \in D$ 且存在乘子 $\lambda^* \in R^{m_1}, \mu^* \in R^{m-m_1}$ 满足(9.7).

(1) 如果 $S(z^*) = \{0\}$, 则 x^* 是问题(9.1)的一个严格局部最优解;

(2) 如果
$$d^T \nabla_x^2 L(z^*) d > 0, \quad \forall 0 \neq d \in S(z^*) \quad (9.9)$$

成立, 则 x^* 是问题(9.1)的一个严格局部最优解.

证明: 采用反证法: 假定 x^* 不是(9.1)的严格局部最优解, 则存在序列 $\{x_k\} \subset D$ 且 $x_k \rightarrow x^*$, 使得 $f(x_k) \leq f(x^*)$.

不妨设

$$d_k = \frac{x_k - x^*}{\|x_k - x^*\|} \rightarrow d \neq 0$$

由于 $\delta_k = x_k - x^* \rightarrow 0$, 且 $x_k = x^* + \delta_k d_k \in D$.

故 $d \in \text{SFD}(x^*, D) \subseteq \text{LFD}(x^*, D)$.

由 $f(x^*) \geq f(x_k) = f(x^*) + \delta_k \nabla f(x^*)^T d_k + o(\delta_k)$

推出： $d^T \nabla f(x^*) \leq 0$

另一方面,由KKT条件(9.7)知,

$$d^T \nabla f(x^*) = \sum_{i \in I(x^*)} \lambda_i^* d^T \nabla g_i(x^*) + \sum_{j \in E} \mu_j^* d^T \nabla h_j(x^*) \geq 0$$

所以

$$d^T \nabla f(x^*) = 0, \quad \lambda_i^* d^T \nabla g_i(x^*) = 0, \forall i \in I(x^*),$$

即 $d \in S(z^*)$. 由于 $\|d\|=1$, 若 $S(z^*) = \{0\}$, 则矛盾。

$$\begin{aligned} \text{又} \quad L(x_k, \lambda^*, \mu^*) &= f(x_k) - \sum_{i \in I} \lambda_i^* g_i(x_k) - \sum_{j \in E} \mu_j^* h_j(x_k) \\ &= f(x_k) - \sum_{i \in I(x^*)} \lambda_i^* g_i(x_k) \leq f(x_k) \end{aligned}$$

以及

$$L(x^*, \lambda^*, \mu^*) = f(x^*) - \sum_{i \in I} \lambda_i^* g_i(x^*) - \sum_{j \in E} \mu_j^* h_j(x^*) = f(x^*)$$

所以

$$\begin{aligned} L(x^*, \lambda^*, \mu^*) &\geq L(x_k, \lambda^*, \mu^*) \\ &= L(x^*, \lambda^*, \mu^*) + \delta_k \nabla_x L(x^*, \lambda^*, \mu^*)^T d_k \\ &\quad + \frac{1}{2} \delta_k^2 d_k^T \nabla_{xx}^2 L(x^*, \lambda^*, \mu^*) d_k + o(\|\delta_k\|^2) \\ &= L(x^*, \lambda^*, \mu^*) + \frac{1}{2} \delta_k^2 d_k^T \nabla_{xx}^2 L(x^*, \lambda^*, \mu^*) d_k + o(\|\delta_k\|^2) \end{aligned}$$

上式两端除以 δ_k^2 并令 $k \rightarrow \infty$, 得

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*, \mu^*) d \leq 0.$$

这与定理假设矛盾. 所以定理成立.

从约束问题的二阶最优性条件可以看出,我们不是从 $\nabla_x^2 L(z^*)$ 的正定性来判断 x^* 是否是最优解.而是考察其在 R^n 的子集 $S(z^*)$ 上正定.

例9.2.4 求下列约束问题的最优解

$$\begin{aligned} \min \quad & f(x) = x_1 \\ \text{s.t.} \quad & g(x) = -(x_1 - 4)^2 - x_2^2 + 16 \geq 0 \\ & h(x) = x_1^2 + (x_2 - 2)^2 - 4 = 0 \end{aligned}$$

解：在例9.2.3中我们已计算出KKT点：

$$\begin{pmatrix} x^{(1)} \\ \lambda_1 \\ \mu_1 \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ 1/8 \\ 0 \end{pmatrix}, \quad \begin{pmatrix} x^{(2)} \\ \lambda_2 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} 8/5 \\ 16/5 \end{pmatrix} \\ 3/40 \\ 1/5 \end{pmatrix}, \quad \begin{pmatrix} x^{(3)} \\ \lambda_3 \\ \mu_3 \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix} \\ 0 \\ 1/4 \end{pmatrix}$$

$$\begin{pmatrix} x^{(1)} \\ \lambda_1 \\ \mu_1 \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ 1/8 \\ 0 \end{pmatrix}, \quad \begin{pmatrix} x^{(2)} \\ \lambda_2 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} 8/5 \\ 16/5 \end{pmatrix} \\ 3/40 \\ 1/5 \end{pmatrix}, \quad \begin{pmatrix} x^{(3)} \\ \lambda_3 \\ \mu_3 \end{pmatrix} = \begin{pmatrix} \begin{pmatrix} 2 \\ 2 \end{pmatrix} \\ 0 \\ 1/4 \end{pmatrix}$$

经计算得：

$$\nabla_x^2 L(z) = \begin{pmatrix} 2(\lambda - \mu) & 0 \\ 0 & 2(\lambda - \mu) \end{pmatrix}$$

在 $x^{(1)}$ 处：

$$\nabla_x^2 L(z^{(1)}) = \begin{pmatrix} 1/4 & 0 \\ 0 & 1/4 \end{pmatrix}$$

即在 $x^{(1)}$ 处 $\nabla_x^2 L(z^{(1)})$ 正定，故 $x^{(1)}$ 是最优解

在 $x^{(2)}$ 处： $\nabla_x^2 L(z^{(2)}) = \begin{pmatrix} -1/4 & 0 \\ 0 & -1/4 \end{pmatrix}$

在 $x^{(2)}$ 处 $\nabla_x^2 L(z^{(2)})$ 负定, 但 $I(x^{(2)}) = \{1\}, \lambda_2 = 3/40 > 0$

$$\nabla g(x^{(2)}) = \begin{pmatrix} 24/5 \\ -32/5 \end{pmatrix}, \quad \nabla h(x^{(2)}) = \begin{pmatrix} 8/5 \\ 6/5 \end{pmatrix} \text{ 线性无关}$$

$$S(z^{(2)}) = \left\{ d \in R^2 \left| \begin{array}{l} 24d_1 - 32d_2 = 0 \\ 8d_1 + 6d_2 = 0 \end{array} \right. \right\} = \{(0, 0)^T\}$$

由于 $S(z^{(2)})$ 中没有非零向量, 因此 $x^{(2)}$ 是严格局部最优解.

在 $x^{(3)}$ 处 $\nabla_x^2 L(z^{(3)}) = \begin{pmatrix} -1/2 & 0 \\ 0 & -1/2 \end{pmatrix}$

在 $x^{(3)}$ 处 $\nabla_x^2 L(z^{(3)})$ 负定, $I(x^{(3)}) = \phi, \lambda_3 = 0,$

$$\nabla h(x^{(3)}) = \begin{pmatrix} 4 \\ 0 \end{pmatrix}$$

$$S(z^{(3)}) = \{d \in R^2 | d_1 = 0, d_2 \in R\} = \{(0, d_2)^T\} | d_2 \in R\}$$

对 $\forall 0 \neq d \in S(z^{(3)})$, 有

$$d^T \nabla_x^2 L(z^{(3)}) d = -\frac{1}{2} d_2^2 < 0,$$

不满足二阶必要条件, 故 $x^{(3)}$ 不是最优解.

例9.2.5 考虑下列约束问题

$$\begin{aligned} \min \quad & f(x) = x_1^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & h(x) = \beta x_1^2 - x_2 = 0 \end{aligned}$$

其中 $\beta \in R$, 讨论取何值时, 点 $x^{(0)} = (0, 0)^T$ 是最优解.

解: $\nabla f(x) = \begin{pmatrix} 2x_1 \\ 2(x_2 - 2) \end{pmatrix}, \quad \nabla h(x) = \begin{pmatrix} 2\beta x_1 \\ -1 \end{pmatrix}$

$$\nabla^2 f(x) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}, \quad \nabla^2 h(x) = \begin{pmatrix} 2\beta & 0 \\ 0 & 0 \end{pmatrix}$$

$$\nabla_x^2 L(x, \mu) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} - \mu \begin{pmatrix} 2\beta & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 2 - 2\beta\mu & 0 \\ 0 & 2 \end{pmatrix}$$

将 $x^{(0)}$ 代入得:

$$\nabla f(x^{(0)}) = \begin{pmatrix} 0 \\ -4 \end{pmatrix}, \quad \nabla h(x^{(0)}) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

令 $\nabla_x L(x^{(0)}, \mu) = \nabla f(x^{(0)}) - \mu \nabla h(x^{(0)}) = 0$, 即

$$\begin{pmatrix} 0 \\ -4 \end{pmatrix} - \mu \begin{pmatrix} 0 \\ -1 \end{pmatrix} = 0, \quad \text{得 } \mu = 4$$

所以在 $x^{(0)}$ 处:

$$\nabla_x^2 L(x^{(0)}, \mu) = \begin{pmatrix} 2 - 8\beta & 0 \\ 0 & 2 \end{pmatrix}$$

计算 $S(x^{(0)}, \mu)$: 令

$$\nabla h(x^{(0)})^T d = 0, \quad (0 \quad -1) \begin{pmatrix} d_1 \\ d_2 \end{pmatrix} = -d_2 = 0$$

所以, $S(x^{(0)}, \mu) = \{(d_1, 0)^T \mid d_1 \in R\}$

此时, $\forall d \in S(x^{(0)}, \mu)$

$$d^T \nabla_x^2 L(x^{(0)}, \mu) d = (d_1 \quad 0) \begin{pmatrix} 2 - 8\beta & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} d_1 \\ 0 \end{pmatrix} = 2(1 - 4\beta) d_1^2$$

$$\forall d \in S(x^{(0)}, \mu)$$

$$d^T \nabla_x^2 L(x^{(0)}, \mu) d = (d_1 \ 0) \begin{pmatrix} 2-8\beta & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} d_1 \\ 0 \end{pmatrix} = 2(1-4\beta)d_1^2$$

(1) 当 $\beta < \frac{1}{4}$ 时, $d^T \nabla_x^2 L(x^{(0)}, \mu) d > 0$, 故 $x^{(0)}$ 是最优解

(2) 当 $\beta > \frac{1}{4}$ 时, $d^T \nabla_x^2 L(x^{(0)}, \mu) d < 0$, 故 $x^{(0)}$ 不是最优解

(3) 当 $\beta = \frac{1}{4}$ 时, $d^T \nabla_x^2 L(x^{(0)}, \mu) d = 0$, 二阶条件失效, 消去 x_1

原问题等价于：

$$\min f(x) = 4x_2 + (x_2 - 2)^2 = x_2^2 + 4$$

显然, $x^{(0)} = (0, 0)^T$ 是最优解.

综上所述：当 $\beta \leq \frac{1}{4}$ 时, $x^{(0)}$ 是最优解, $\beta > \frac{1}{4}$ 时则不是.

作 业

- 习题9

- 4, 8, 18