

# 第26-27讲 增广目标函数法

## 约束优化问题

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i \in \mathcal{I} = \{1, \dots, m_1\}, \\ & h_j(x) = 0, \quad j \in \mathcal{E} = \{m_1 + 1, \dots, m\}.\end{array}$$

$$g_{\mathcal{I}}(x) = (g_1(x), \dots, g_{m_1}(x))^T, \quad h_{\mathcal{E}}(x) = (h_{m_1+1}(x), \dots, h_m(x))^T.$$



$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_{\mathcal{I}}(x) \geq 0, \\ & h_{\mathcal{E}}(x) = 0.\end{array} \quad (12.1)$$

可行域为

$$D = \{x \mid g_{\mathcal{I}}(x) \geq 0, \quad h_{\mathcal{E}}(x) = 0\}.$$

# 罚函数法

## 外点罚函数法

基本思想: 构造辅助函数  $F_\mu : R^n \rightarrow R$ , 其中参数  $\mu > 0$ .

函数  $F_\mu$  在可行域  $D$  的内部的取值与问题 (12.1) 的目标函数  $f$  的取值相等, 对可行域外部点的目标函数值加以惩罚,  $\min F_\mu(x)$  的解是(12.1)的近似解.

当  $\mu \rightarrow \infty$  时, 问题  $\min F_\mu(x)$  的解  $x(\mu)$  趋于约束问题 (12.1) 的解.

例

$$\begin{array}{ll} \min & f(x) = x^2 \\ \text{s.t.} & g(x) = -x - 1 \geq 0. \end{array}$$

令  $S(x) = \min^2\{g(x), 0\}.$

则  $S(x) = 0 \iff x \in D.$

令  $P_\mu(x) = \frac{1}{2}\mu S(x) = \frac{1}{2}\mu \min^2\{g(x), 0\}.$

构造辅助函数  $F_\mu$

$$F_\mu(x) = f(x) + P_\mu(x) = f(x) + \frac{1}{2}\mu \min^2\{g(x), 0\}.$$

则




图 12.1：问题 (12.2) 的可行域和最优解.

$$D = (-\infty, -1] \text{ 和 } x^* = -1.$$

无约束问题  $\min F_\mu(x)$  的解为  $x(\mu) = -\frac{\mu}{2 + \mu}$ .

当  $\mu \rightarrow +\infty$  时,  $x(\mu) \rightarrow -1 = x^*$ .




图 12.2： 增广目标函数  $F_\mu(x)$  及其极小值点.

对一般的约束问题 (12.1), 我们引入如下函数:

$$S(x) = \|h_{\mathcal{E}}(x)\|^2 + \|\min\{g_{\mathcal{I}}(x), 0\}\|^2,$$

$$P_{\mu}(x) = \frac{1}{2}\mu S(x), \quad F_{\mu}(x) = f(x) + P_{\mu}(x).$$

显然有  $F_{\mu}(x) = f(x)$ ,  $\forall x \in D$ . 而且, 当  $\mu > 0$  很大时, 对任何  $x \notin D$ , 有  $F_{\mu}(x) \gg f(x)$ .

### 算法 12.1 (外点罚函数法)

步 0 取初始点  $x^{(0)} \in R^n$ . 罚参数序列  $\{\mu_k\}$ , 精度  $\epsilon > 0$ . 令  $k := 0$ .

步 1 构造增广目标函数

$$F_{\mu_k}(x) = f(x) + P_{\mu_k}(x) = f(x) + \frac{1}{2}\mu_k \left( \|h_{\mathcal{E}}(x)\|^2 + \|\min\{g_{\mathcal{I}}(x), 0\}\|^2 \right).$$

步 2 求解无约束问题

$$\min F_{\mu_k}(x), \quad x \in R^n$$

得解  $x^{(k)}$ .

步 3 若  $P_{\mu_k}(x^{(k)}) \leq \epsilon$  或

$$-\min\{g_i(x^{(k)}) \mid i \in \mathcal{I}\} \leq \epsilon, \quad \max\{|h_j(x^{(k)})| \mid j \in \mathcal{E}\} \leq \epsilon,$$

则得解  $x^{(k)}$ , 否则, 令  $k := k + 1$ . 转步 1.

**定理 12.1.1** 设函数  $f, g_i, h_j, i \in \mathcal{I}, j \in \mathcal{E}$  连续且约束问题 (12.1) 的解存在. 设  $\{x^{(k)}\}$  由算法 12.1 产生, 其中罚参数序列  $\{\mu_k\}$  单调递增且趋于  $+\infty$ . 则  $\{x^{(k)}\}$  的任何极限点都是问题 (12.1) 的解.

例 12.1.1 用外点罚函数法求解约束问题

$$\begin{aligned} \min \quad & f(x) = \frac{1}{2}x_1^2 + \frac{1}{6}x_2^2 \\ \text{s.t.} \quad & h(x) = x_1 + x_2 - 1 = 0. \end{aligned}$$

取罚参数序列为  $\mu_k = 2^{k-1}$ .

解 构造增广目标函数  $F_\mu$  如下:

$$F_\mu(x) = f(x) + \frac{1}{2}\mu h^2(x) = \frac{1}{2}x_1^2 + \frac{1}{6}x_2^2 + \frac{1}{2}\mu(x_1 + x_2 - 1)^2.$$

由计算得  $\nabla F_\mu(x) = (x_1 + \mu(x_1 + x_2 - 1), \frac{1}{3}x_2 + \mu(x_1 + x_2 - 1))^T$ .

$F_\mu$  是二次凸函数

$$\min F_\mu(x), \quad x \in R^n \quad \longleftrightarrow \quad \nabla F_\mu(x) = 0$$

$$\longleftrightarrow \quad \begin{cases} x_1 + \mu(x_1 + x_2 - 1) & = 0, \\ \frac{1}{3}x_2 + \mu(x_1 + x_2 - 1) & = 0 \end{cases}$$

$$\longrightarrow \quad x_\mu = \left( \frac{\mu}{1+4\mu}, \frac{3\mu}{1+4\mu} \right)^T. \quad \longrightarrow \quad x^{(k)} = \left( \frac{2^{k-1}}{1+2^{k+1}}, \frac{3 \times 2^{k-1}}{1+2^{k+1}} \right)^T.$$

$$\longrightarrow \quad x^{(k)} \rightarrow x^* = (1/4, 3/4)^T.$$

## 结论说明

约束优化问题有最优解，不能保证罚函数有最优解.

A、罚因子取值太小，目标函数的下降度不能抵消对不可行点的惩罚度.

例

$$\begin{aligned} \min & -x_1^2 + x_2^2 \\ \text{s.t. } & x_1 = 1 \end{aligned}$$

最优解(1,0)

$$P(\mathbf{x}, \pi) = -x_1^2 + x_2^2 + \pi(x_1 - 1)^2 \quad \text{在 } \pi < 1 \text{ 时没有最优解。}$$

目标函数与惩罚项同阶，罚因子太小，目标函数主导罚函数的值



**B、** 目标函数阶数高于惩罚项阶数，目标函数的下降速度远高于惩罚项的下降速度

例  $\min -x_1^5$   
s.t.  $x_1^2 + x_2^2 = 1$

最优解(1;0)

$P(\mathbf{x}, \pi) = -x_1^5 + \pi(x_1^2 + x_2^2 - 1)^2$  对任意  $\pi > 0$  均无最优解。

目标函数阶数高于惩罚项阶数，目标函数主导罚函数

## 算法缺陷

随罚因子增大，子问题病态加剧，从而导致算法稳定性差.

**原问题**  $\min \{f(\mathbf{x}) \mid c_i(\mathbf{x}) = 0, i \in \mathcal{E}\}$

**外点罚函数**  $P(\mathbf{x}, \pi) = f(\mathbf{x}) + \pi \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x})$

**Hesse阵**  $\nabla_{xx}P(\mathbf{x}, \pi) = \nabla^2 f(\mathbf{x}) + \sum_{i \in \mathcal{E}} 2\pi c_i(\mathbf{x}) \nabla^2 c_i(\mathbf{x}) + 2\pi \mathbf{N}(\mathbf{x}) \mathbf{N}(\mathbf{x})^T$



$$\lambda_i = -2\pi c_i(x)$$

$$\nabla_{xx}P(x, \pi) \approx \nabla_{xx}L(x, \lambda) + 2\pi \mathbf{N}(x) \mathbf{N}(x)^T$$



矩阵 $\mathbf{N}(x) \mathbf{N}(x)^T$ 奇异

罚函数条件数  $\kappa(\nabla_{xx}P(\mathbf{x}, \pi)) \rightarrow \infty, \pi \rightarrow \infty$  子问题病态!

## 外点罚函数病态实例

例：考虑约束优化问题

$$\begin{array}{ll}\min & x_1^2 + x_2^2 \\ \text{s. t.} & x_1 + 1 = 0\end{array}$$

分析：外点罚函数

$$F(x, \pi) = x_1^2 + x_2^2 + \pi(x_1 + 1)^2$$

Hesse矩阵

$$\nabla_{xx}F(x, \pi) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} + \begin{pmatrix} 2\pi & 0 \\ 0 & 0 \end{pmatrix}$$

Hesse矩阵条件数

$$\kappa(\nabla_{xx}F(x, \pi)) = \frac{2 + 2\pi}{2} \rightarrow \infty, \quad (\pi \rightarrow \infty)$$

# 内点罚函数法

考察约束问题

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i \in \mathcal{I}. \end{array}$$

内点罚函数法的基本思想是：构造辅助 (光滑) 函数  $F_\mu$ , 该函数在严格可行域  $D_0$  以外的取值为无穷大, 而且, 当点  $x$  从  $D_0$  趋于  $D$  的边界时, 函数值趋于无穷大. 这样, 无约束问题  $\min F_\mu(x)$  的解一定在  $D_0$  内. 我们希望当  $\mu$  趋于无穷大时, 无约束问题  $\min F_\mu(x)$  的解  $x(\mu)$  趋于约束问题 (12.6) 的解. 辅助函数  $F_\mu$  在  $D$  的边界筑起了一道很高的墙, 把无约束问题  $\min F_\mu(x)$  的解挡在了可行域  $D$  的内部. 因此, 内点罚函数法也称为障碍函数法.

$$F_\mu(x) = f(x) - \mu^{-1} \sum_{i \in \mathcal{I}} \log g_i(x).$$

称函数  $S(x) = -\sum_{i \in \mathcal{I}} \log g_i(x)$  为对数障碍函数.

例

$$\begin{array}{ll} \min & f(x) = x^2 \\ \text{s.t.} & g(x) = -x - 1 \geq 0. \end{array}$$

$$F_\mu(x) = x^2 - \mu^{-1} \log[-(x+1)],$$

相应的无约束问题  $\min F_\mu(x), \quad x \in R$  的解为

$$x(\mu) = -\frac{1 + \sqrt{1 + 2\mu^{-1}}}{2} \longrightarrow -1 = x^*, \mu \rightarrow \infty.$$




图 12.3：辅助目标函数  $F_\mu(x)$  及其极小值点.

## 算法 12.2 (内点罚函数法)

步 0 取初始点  $x^{(0)} \in D_0$ . 罚参数序列  $\{\mu_k\}$ , 精度  $\epsilon > 0$ . 令  $k := 0$ .

步 1 构造辅助函数

$$F_{\mu_k}(x) = f(x) + \mu_k^{-1} S(x) = f(x) - \mu_k^{-1} \sum_{i \in \mathcal{I}} \log g_i(x).$$

步 2 以  $x^{(k-1)}$  作为初始点, 求解无约束问题  $\min F_{\mu_k}(x)$ ,  $x \in R^n$  得解  $x^{(k)}$ .

步 3 若

$$-\mu_k^{-1} \sum_{i \in \mathcal{I}} \log g_i(x) \leq \epsilon,$$

则得解  $x^{(k)}$ . 否则, 令  $k := k + 1$ . 转步 1.

**定理 12.1.2** 设函数  $f, g_i, i \in \mathcal{I}$  连续可微,  $D_0$  非空且其闭包为  $D$ . 再设问题 (12.6) 有解,  $\{x^{(k)}\}$  由算法 12.2 产生, 其中罚参数序列  $\{\mu_k\}$  单调递增且趋于  $+\infty$ . 则  $\{x^{(k)}\}$  的任何极限点都是问题 (12.6) 的解.

## 内点罚函数方法的收敛性

对数障碍函数的最优值点列的聚点为原问题的K-T点

一阶最优性条件:

$$\nabla_x F(x_\pi, \pi) = \nabla f(x_\pi) - \sum_{i \in I} \frac{1}{\pi c_i(x_\pi)} \nabla c_i(x_\pi) = 0$$



$$\lambda_i(\pi) := \frac{1}{\pi c_i(x_\pi)}, i \in I$$



$$\nabla_x L(x_\pi, \lambda(\pi)) = \nabla f(x_\pi) - \sum_{i \in I} \lambda_i(\pi) \nabla c_i(x_\pi) = 0$$

KKT条件  
第一式

对任意  $i \in I$ ,  $\lambda_i(\pi) c_i(x_\pi) = \frac{1}{\pi} \rightarrow 0, \pi \rightarrow \infty$  互补松弛条件



## 罚函数法存在的问题:

$x^{(k)}$  是问题 (12.8) 的解  $x^*$  的近似,  $\mu_k$  必须充分大.

当  $\mu_k$  很大时, 函数  $F_{\mu_k}$  的 Hessian 阵会出现病态.

为了克服由于罚参数过大而引起的数值计算上的困难, 我们构造函数  $L_\mu(x)$ , 使得当罚参数  $\mu$  相对较小时, 无约束问题  $\min L_\mu(x)$  的解  $x(\mu)$  也是约束问题 (12.8) 的解的一个很好的近似.

Hestenes和Powell(1969)将Lagrange函数与外点罚函数相结合，建立了等式约束优化问题的增广Lagrange罚函数(乘子罚函数)。

Rockafeller (1973)将其推广到不等式约束优化问题, 建立了约束优化问题的乘子罚函数。

# 乘子法

## 等式约束问题的乘子法

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & h_i(x) = 0, i \in \mathcal{E} = \{m_1 + 1, \dots, m\} \end{array}$$

增广 Lagrange 函数

$$L_\mu(x, \lambda) = L(x, \lambda) + \frac{1}{2}\mu S(x) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i h_i(x) + \frac{1}{2}\mu \sum_{i \in \mathcal{E}} h_i^2(x).$$

迭代格式

给定  $\mu_k$  和  $\lambda^{(k)}$ ,

$$x^{(k)} = \operatorname{argmin}_{\mu_k} L_{\mu_k}(x, \lambda^{(k)})$$

$$\lambda_i^{(k+1)} = \lambda_i^{(k)} - \mu_k h_i(x^{(k)}), i \in E$$

**定理 12.2.1** 设  $x^{(k)}$  是无约束问题

$$\min L_{\mu_k}(x, \lambda^{(k)}), \quad x \in R^n$$

的解, 则  $x^{(k)}$  也是约束问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = h_i(x^{(k)}), \quad i \in \mathcal{E} \end{aligned}$$

的解.

**定理 12.2.2** 设  $x^*$  是问题 (12.8) 的一个局部最优解且  $LICQ$  在  $x^*$  处成立, 即  $\nabla h_j(x^*), j \in \mathcal{E}$  线性无关. 再设在  $x^*$  处二阶充分条件成立. 则存在  $\bar{\mu} > 0$ , 使得对所有  $\mu \geq \bar{\mu}$ ,  $x^*$  是无约束问题

$$\min L_{\mu}(x, \lambda^*) = f(x) - \sum_{i \in \mathcal{E}} \lambda_i^* h_i(x) + \frac{1}{2} \mu \sum_{i \in \mathcal{E}} h_i^2(x) \quad (12.15)$$

的严格局部最优解, 其中  $\lambda^*$  为解  $x^*$  处的 *Lagrange* 乘子.

增广拉格朗日法本质上是: 近似牛顿法

结论意义：无需罚因子趋于无穷,由乘子罚函数可得原问题最优解.

缺陷：无法保证Lagrange乘子的取值！

解决途径：逐步调整

对给定的 $\lambda^k, \pi_k$ , 计算乘子罚函数 $P(x, \lambda^k, \pi_k)$ 的值点得 $x_k$

$$\nabla f(x_k) - \sum_{i \in \mathcal{E}} \lambda_i^k \nabla c_i(x_k) + 2\pi_k \sum_{i \in \mathcal{E}} c_i(x_k) \nabla c_i(x_k) = 0$$



$$\nabla f(x_k) = \sum_{i \in \mathcal{E}} (\lambda_i^k - 2\pi_k c_i(x_k)) \nabla c_i(x_k) \xrightarrow{\text{KKT条件}} \lambda_i^{k+1} = \lambda_i^k - 2\pi_k c_i(x_k)$$

若 $x_k$ 为乘子罚函数最优解,且为可行点,则为最优解和K-T点,算法终止

终止条件： $\|c(x_k)\|_\infty \leq \varepsilon$ .

初始步

步1、取  $\pi_1 > 0$ ,  $\boldsymbol{\lambda}^1 = \mathbf{0}$ ,  $\mathbf{x}_0 \in \mathbb{R}^n$ ,  $\gamma > 1$ ,  $\varepsilon > 0$ . 令  $k = 1$ .

迭代步

步2、以  $\mathbf{x}_{k-1}$  为初始点, 求  $P(\mathbf{x}, \boldsymbol{\lambda}^k, \pi_k)$  的最小值点得  $\mathbf{x}_k$ .

步3、若  $\max\{|c_i(\mathbf{x}_k)| \mid i \in \mathcal{E}\} \leq \varepsilon$ , 算法终止. 否则, 转下一步.

校正步

步4、若  $\|\mathbf{c}(\mathbf{x}_k)\|_\infty \geq \|\mathbf{c}(\mathbf{x}_{k-1})\|_\infty$ , 令  $\pi_{k+1} = \gamma\pi_k$ ,  $\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k$ ,

置  $k = k + 1$ , 转步2. 否则, 转步5.

罚因子  
乘子

步5、若  $\pi_k > \pi_{k-1}$  或  $\|\mathbf{c}(\mathbf{x}_k)\|_\infty \leq \frac{1}{4}\|\mathbf{c}(\mathbf{x}_{k-1})\|_\infty$ , 令  $\pi_{k+1} = \pi_k$ ,

调整Lagrange乘子:  $\lambda_i^{k+1} = \lambda_i^k - 2\pi_k c_i(\mathbf{x}_k)$

置  $k = k + 1$ , 转步2; 否则, 令  $\boldsymbol{\lambda}^{k+1} = \boldsymbol{\lambda}^k$ ,  $\pi_{k+1} = \gamma\pi_k$ ,

置  $k = k + 1$ , 转步2.

# 不等式约束优化

$$\min f(x) \quad \text{s.t.} \quad g_i(x) \geq 0, \quad i \in I$$

$$\min f(x) \quad \text{s.t.} \quad g_i(x) - z_i^2 = 0, \quad i \in I$$

$$L_\mu(x, z, \lambda) = f(x) - \sum_{i \in I} \lambda_i (g_i(x) - z_i^2) + \frac{\mu}{2} \sum_{i \in I} (g_i(x) - z_i^2)^2$$

$$\min_x \min_{s \geq 0} L_\mu(x, s, \lambda) = f(x) - \sum_{i \in I} \lambda_i (g_i(x) - s_i) + \frac{\mu}{2} \sum_{i \in I} (g_i(x) - s_i)^2$$

$$\min_{s \geq 0} L_\mu(x, s, \lambda) = f(x) - \sum_{i \in I} \lambda_i (g_i(x) - s_i) + \frac{\mu}{2} \sum_{i \in I} (g_i(x) - s_i)^2$$

$$s_i = \max \left\{ 0, g_i(x) - \frac{1}{\mu} \lambda_i \right\}$$

## 不等式约束问题

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i \in \mathcal{I} = \{1, 2, \dots, m_1\},\end{array}$$

$$\begin{aligned}\bar{g}_i(x, z(x)) &= g_i(x) - z_i^2(x) = g_i(x) - \mu^{-1} \max\{0, \mu g_i(x) - \lambda_i\} \\ &= \mu^{-1} \left( \min\{\mu g_i(x), \lambda_i\} \right) = \mu^{-1} \left( \min\{\mu g_i(x) - \lambda_i, 0\} + \lambda_i \right).\end{aligned}\quad (12.23)$$

增广 Lagrange 函数为

$$\begin{aligned}L_\mu(x, \lambda) &= f(x) - \sum_{i \in \mathcal{I}} \lambda_i \bar{g}_i(x, z(x)) + \frac{1}{2} \mu \sum_{i \in \mathcal{I}} \bar{g}_i^2(x, z(x)) \\ &= f(x) - \mu^{-1} \sum_{i \in \mathcal{I}} \lambda_i \left( \min\{\mu g_i(x) - \lambda_i, 0\} + \lambda_i \right) + \frac{1}{2} \mu^{-1} \sum_{i \in \mathcal{I}} \left( \min\{\mu g_i(x) - \lambda_i, 0\} + \lambda_i \right)^2 \\ &= f(x) + \frac{1}{2} \mu^{-1} \sum_{i \in \mathcal{I}} \left( \min^2\{\mu g_i(x) - \lambda_i, 0\} - \lambda_i^2 \right).\end{aligned}$$

迭代格式

给定  $\mu_k$  和  $\lambda^{(k)}$ ,

$$x^{(k)} = \operatorname{argmin}_x L_{\mu_k}(x, \lambda^{(k)})$$

$$\lambda^{(k+1)} = \arg \max_{\lambda \geq 0} L_{\mu_k}(x^{(k)}, \lambda),$$



$$\max_{\lambda \geq 0} L_{\mu}(x^k, \lambda) \Leftrightarrow \min_{\lambda \geq 0} -L_{\mu}(x^k, \lambda)$$

$$L_{\mu}(x, \lambda) = f(x) - \sum_{i \in I} \lambda_i g_i(x) + \frac{\mu}{2} \min^2\{g_i(x), 0\}$$

$$\nabla_{\lambda}[-L_{\mu}(x^k, \lambda)] = g(x^k)$$

$$\min_{\lambda \geq 0} -L_{\mu}(x^k, \lambda) \Leftrightarrow g(x^k)^T(\lambda - \lambda^*) \geq 0, \forall \lambda \geq 0$$

$$\begin{aligned} \Leftrightarrow \lambda^* &= P_{\lambda \geq 0}(\lambda^* - \rho g(x^k)) \\ &= \max\{\lambda^* - \rho g(x^k), 0\} \end{aligned}$$

特别地，取  $\rho = \mu_k$ ，有

$$\lambda^{(k+1)} = \max\{\lambda^k - \mu_k g(x^k), 0\}$$

### 一般约束问题

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & g_i(x) \geq 0, \quad i \in \mathcal{I}, \\ & h_j(x) = 0, \quad j \in \mathcal{E}\end{array}$$

增广 Lagrange 函数为

$$L_\mu(x, \lambda) = f(x) + \frac{1}{2}\mu^{-1} \sum_{i \in \mathcal{I}} \left( \min^2\{\mu g_i(x) - \lambda_i, 0\} - \lambda_i^2 \right) - \sum_{j \in \mathcal{E}} \lambda_j h_j(x) + \frac{1}{2}\mu \sum_{j \in \mathcal{E}} h_j^2(x).$$

相应的乘子迭代格式为：

$$\lambda_j^+ = \begin{cases} \lambda_j - \mu h_j(x), & j \in \mathcal{E}, \\ \max\{\lambda_i - \mu g_i(x), 0\}, & i \in \mathcal{I}, \end{cases} \quad (12.28)$$

其中， $x, \mu, \lambda$  表示当前迭代点的值， $\lambda^+$  表示下一次迭代的乘子向量。

### 算法 12.4 ( 乘子法 )

步 0 取初始点  $x^{(0)} \in R^n$ , 初始乘子向量  $\lambda^{(0)}$ . 给定罚参数序列  $\{\mu_k\}$ , 精度  $\epsilon > 0$ . 令  $k := 0$ .

步 1 由 (12.27) 构造增广 *Lagrange* 函数  $L_\mu(x, \lambda)$ .

步 2 以  $x^{(k-1)}$  作为初始点 ( $k = 0$  时, 初始点任意), 求解无约束问题

$$\min L_{\mu_k}(x, \lambda^{(k)}), \quad x \in R^n$$

得解  $x^{(k)}$ .

步 3 ( 终止准则 ) 若

$$\|h_{\mathcal{E}}(x^{(k)})\| + \|\min\{g_{\mathcal{I}}(x^{(k)}), \mu_k^{-1}\lambda_{\mathcal{I}}^{(k)}\}\| \leq \epsilon,$$

则得解  $x^{(k)}$ .

步 4 ( 进行乘子迭代 ) : 由 (12.28) 确定  $\lambda^{(k+1)}$ . 令  $k := k + 1$ . 转步 1.


例 12.2.2 用算法 12.4 求解下面的约束问题:

$$\begin{array}{ll}\min & f(x) = x_1^2 + x_2^2 \\ \text{s.t.} & g(x) = x_1 - 1 \geq 0.\end{array}$$

取  $\mu_k = 4$ ,  $\lambda_0 = 0$ .

解 问题的增广 Lagrange 函数为

$$\begin{aligned}L_\mu(x, \lambda) &= x_1^2 + x_2^2 + \frac{1}{2}\mu^{-1} \left[ \min^2\{\mu(x_1 - 1) - \lambda, 0\} - \lambda^2 \right] \\ &= \begin{cases} x_1^2 + x_2^2 + \frac{1}{2}\mu(x_1 - 1)^2 - \lambda(x_1 - 1), & \text{若 } x_1 \leq 1 + \mu^{-1}\lambda, \\ x_1^2 + x_2^2 - \frac{1}{2}\mu^{-1}\lambda^2, & \text{若 } x_1 > 1 + \mu^{-1}\lambda. \end{cases}\end{aligned}$$


$$\frac{\partial L_\mu(x, \lambda)}{\partial x_1} = \begin{cases} 2x_1 + \mu(x_1 - 1) - \lambda, & \text{若 } x_1 \leq 1 + \mu^{-1}\lambda, \\ 2x_1, & \text{若 } x_1 > 1 + \mu^{-1}\lambda. \end{cases}$$

$$\frac{\partial L_\mu(x, \lambda)}{\partial x_2} = 2x_2.$$

由  $\nabla_x L_\mu(x, \lambda) = 0$  得无约束问题  $\min_x L_\mu(x, \lambda_k), \quad x \in R^n$  的极小值点

$$x^{(k)} = \left( \frac{\lambda_k + \mu_k}{2 + \mu_k}, 0 \right)^T = \left( \frac{\lambda_k + 4}{6}, 0 \right)^T.$$

乘子满足:

$$\lambda_{k+1} = \max\{\lambda_k - 4(x_1^{(k)} - 1), 0\} = \max\{\frac{\lambda_k + 4}{3}, 0\} = \frac{\lambda_k + 4}{3}.$$

因此,  $\lambda_k \rightarrow 2, x^{(k)} \rightarrow (1, 0)^T, k \rightarrow \infty.$

可以看出, 用乘子法产生的点列收敛于问题的解. 而且, 罚参数  $\mu_k$  不必趋于  $+\infty$ .

# 作业

- 10(1) 内点和外点罚函数法分别求解
- 20(ii)
- 16(思考题, 不做为作业)